



République Algérienne Démocratique et Populaire



Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

Université des Sciences et de la Technologie Houari Boumediene

**Faculté d'Informatique
Département Informatique**

Mémoire de Licence

Filière : Informatique

Spécialité :

Ingénierie des Systèmes d'information et des Logiciels

Thème

Prédiction des feux de forêts par l'intelligences artificielle

Sujet Proposé par :

Mr. BESSAA Brahim

Mr. ATIF Karim

Soutenu le : 04/06/2024

Présenté par : BOUTEHRA Douaa

BERRAIS Wafaa

Devant le jury composé de :

Mme. BOUGHACI Dalila (Présidente)

Mr. HAOUARI Taha (Membre)

Binôme n° : 028 /2024

Remerciements

En préambule à ce projet, nous remercions ALLAH qui nous a aidés et nous a donné la patience et le courage durant ces longues années d'étude.

Nous exprimons aussi nos vifs remerciements aux membres du jury, Professeurs Mme D. BOUGHACI et Monsieur T. HAOUARI pour l'intérêt qu'ils ont porté à notre recherche en acceptant d'examiner notre travail et de l'enrichir par leurs remarques.

Nous adressons nos sincères remerciements à nos encadrants, Monsieur BESSAA Brahim et Monsieur ATIF Karim, à qui nous exprimons toute notre reconnaissance, de nous avoir encadrés et encouragés tout le long de notre stage. Merci pour leur bonne volonté, leur patience et leurs précieux conseils ainsi que pour la pertinence de leurs remarques.

Nous tenons à exprimer notre profonde reconnaissance à nos professeurs, en particulier à M. Boudour Rachid, Mme Houasine Nailla, M. Guenfaf Youcef, ainsi qu'à Mme Belhadj et son équipe. Leurs conseils, leurs critiques constructives et leur disponibilité ont été essentiels à la réalisation de ce travail.

Nous ne saurons jamais assez remercier la lumière de notre vie, nos parents, qui par leurs prières et leurs encouragements, nous ont permis de surmonter tous les obstacles.

Pour conclure, nous souhaitons adresser nos remerciements à tout l'ensemble du professeurs du la Faculté d'informatique, ainsi qu'à tous ceux qui, de près ou de loin, ont contribué à la réalisation de ce travail.

Dédicace

Je dédie cet ouvrage à ma maman, qui m'a soutenu et encouragé durant toutes ces années d'études. Qu'elle trouve ici le témoignage de ma profonde reconnaissance.

À ma sœur, mes grands-parents, mes oncles, tantes, petits cousins, ainsi qu'à tous ceux qui ont partagé avec moi des moments d'émotion lors de la réalisation de ce travail. Ils m'ont chaleureusement supporté et encouragé tout au long de mon parcours.

À mes enseignants, qui m'ont aidé tout au long de mon parcours, par leurs conseils et leur dévouement.

À ma famille, mes proches et à ceux qui me donnent de l'amour et de la vivacité.

À tous mes chers amis qui m'ont toujours encouragé, et à qui je souhaite un succès continu.

À tous ceux que j'aime, cette dédicace est pour vous.

Wafaa

Dédicace

À mes chers parents, je vous remercie pour tout le soutien et l'amour que vous m'avez portés depuis mon enfance. J'espère que votre bénédiction m'accompagnera toujours. Que ce modeste travail soit l'exaucement de vos vœux, le fruit de vos innombrables sacrifices.

À mon très cher frère Souleimane.

À mes adorables sœurs : Radiaa la persévérante, Anfel la petite sympa.

À la mémoire de ma grand-mère, j'aurais tant aimé que vous soyez là pour vivre ces moments avec nous. Que Allah ait vos âmes dans Sa sainte miséricorde.

Mes chers amis, Amira Bouchekir, Ibtissem Kasraoui, qui m'ont beaucoup inspirée pour devenir la jeune fille que je suis aujourd'hui.

Je dédie ce travail...

Douaa

Table des matières

Table des figures

Liste des tableaux

Liste des algorithmes

Liste des abréviations

Résumé

Abstract

Introduction générale

1 Feux de forêt

1.1 Introduction	1
1.2 Incendies de forêt.....	1
1.3 Types d'incendies de forêt	1
1.4 Facteurs influents dans la propagation du feu	1
1.5 Causes principales des incendies	2
1.6 Impacts des incendies de forêt.....	2
1.7 Stratégies de prévention.....	3
1.8 Problématique.....	3
1.9 Objectifs.....	3
1.10 Conclusion	3

2 Analyse prédictive et apprentissage automatique

2.1 Introduction	4
2.2 Analyse prédictive.....	4
2.3 Intelligence artificielle.....	4
2.4 Apprentissage automatique.....	4
2.5 Type d'apprentissage automatique	5
2.6 Analyse Prédictive et apprentissage automatique	10
2.7 Travaux connexes	10
2.8 Étude comparative	12
2.9 Conclusion.....	14

3 Conception

3.1 Introduction	15
3.2 Schéma représentatif de notre système	16
3.3 Conception de jeux de données	17

3.3.1 Présentation et justification de choix de région d'étude	17
3.3.2 Données d'étude.....	18
3.3.3 Méthodologie de construction de jeux de données	20
3.4 Modèles prédictifs	25
3.4.1 Support à vecteur machines	25
3.4.2 Arbre de décision	26
3.4.3 Régression logistique.....	27
3.4.5 Réseau de neurones multicouches	29
3.4.6 Modèles ensembliste.....	30
3.5 Cartographier le risque	33
3.6 Conclusion	35

4 Implémentation

4.1 Introduction	36
4.2 Description matérielle.....	36
4.3 Description logicielle.....	36
4.4 Présentation de l'application.....	38
4.5 Résultats et discussions	40
4.5.1 Présentation de jeux de donnée.....	40
4.5.2 Prétraitement.....	42
4.5.3 Métriques d'évaluation	43
4.5.4 Résultat d'évaluation des modèles prédictives	44
4.5.5 Résultat de calcul de l'indice de risque.....	49
4.5.6 Comparaison entre le modèle intelligent et l'indice de risque statique.....	52
4.6 Conclusion	52

Conclusion générale

Bibliographie

Annexe A

Annexe B

Annexe C

Table des figures

Figure 1 : Les trois facteurs qui conditionnent le phénomène feux de forêt	1
Figure 2 : Apprentissage automatique Supervisé	5
Figure 3 : Apprentissage automatique non-supervisé	8
Figure 4 : Apprentissage automatique semi-supervisé	9
Figure 5 : Apprentissage par renforcement	9
Figure 6 : L'architecture globale du système	16
Figure 7 : Carte de Bejaia	17
Figure 8 : Carte des pentes de Bejaia	20
Figure 9 : Support à vecteur machines	26
Figure 10 : Arbre de décision	27
Figure 11 : la fonction sigmoïde	28
Figure 12 : réseau de neurones multicouche	29
Figure 13 : Méthode bagging	31
Figure 14 Méthode boosting	32
Figure 15 matrice de confusion	49
Figure 16 : Carte de l'indice de combustibilité	50
Figure 17 : Carte de l'indice de topo morphologique	50
Figure 18 : Carte de l'indice de d'occupation humaine	51
Figure 19 : Carte d'indice de risque	52
Figure 20 Système d'information géographique	38
Figure 21 : carte de biovolume	40
Figure 22 Carte des notes de combustibilité	40
Figure 23 Carte de proximité routes	41
Figure 24 Carte de voisinage	41
Figure 25 la carte La position des versants	42

Liste des tableaux

Tableau 1 : Les caractéristiques des approches abordées.....	13
Tableau 2 : Résultats d’entraînement avec le jeu de données 1	45
Tableau 3 : Résultat d’entraînement avec le jeu de données 2.....	46
Tableau 4 : résultats d’entraînement avec le jeu de données 3.....	47
Tableau 5 : résultat d’entraînement avec le jeu de données 4	48

Liste des algorithmes

Algorithme 1 : Création des sous jeux de données équilibrés.....	23
Algorithme 2 : Construction de nos jeux de données.....	24
Algorithme 3 : Formation des perceptrons multicouches.....	29

Liste des abréviations

SIG	Système d'information géographique
IA	Intelligence Artificielle
SVM	Support à vecteur machine
MLP	Multi layer perceptrons
ANN	Artificielle nuerons network
DT	Decision Tree
RF	Random forest
RL	Régression Logistique
ML	Machine learning
NDVI	Normalized Difference Vegetation Index
NDWI	Normalized Difference Water Index
LULC	Land Use / Land Cover
ASI	Agriculture Stress Index
VHI	Vegetation Health Index
PI	Precipitation Index
XGB	XGBoost
AB	Ada Boost
BC	Bagging Classifier
IR	Indice de Risque
IM	Indice Topo-morphologique
IC	Indice de Combustibilité
IH	Indice d'occupation Humaine

Résumé

Les incendies de forêt représentent un défi considérable en Algérie, provoquant des dommages importants annuellement. Dans ce mémoire, nous étudions comment l'intelligence artificielle peut être employée pour prédire et gérer ces incendies. Nous commençons par une analyse détaillée des incendies de forêt, en abordant leurs types, les facteurs de propagation, les causes principales et les stratégies de prévention. Ensuite, nous explorons diverses méthodes d'apprentissage automatique, telles que les machines à vecteurs de support, les arbres de décision, la régression logistique, les réseaux de neurones multicouches et les modèles ensemblistes, appliquées à des jeux de données spécifiques. Pour évaluer et visualiser les résultats des modèles prédictifs, nous avons utilisé l'indice de risque d'incendie, permettant de cartographier le risque et les attribuer aux zones identifiées comme étant à risque par le modèle intelligent. En développant une application web, nous offrons une interface intuitive pour visualiser ces zones, facilitant ainsi la gestion et la prévention des incendies. Cette étude démontre que l'intelligence artificielle peut significativement améliorer la prédiction et la gestion des incendies de forêt en Algérie, contribuant à réduire les pertes humaines et matérielles.

Mots clé: modèle prédictif, intelligence artificielle, feux de forêt.

Abstract

Wildfires represent a significant challenge in Algeria, causing substantial damage annually. In this thesis, we explore how artificial intelligence can be employed to predict and manage these fires. We begin with a detailed analysis of wildfires, addressing their types, propagation factors, main causes, and prevention strategies. Next, we investigate various machine learning methods, such as support vector machines, decision trees, logistic regression, multilayer neural networks, and ensemble models, applied to specific datasets. To evaluate and visualize the predictive models' results, we used the fire risk index, enabling us to map the risk and assign it to areas identified as high-risk by the intelligent model. By developing a web application, we provide an intuitive interface to visualize these areas, thereby facilitating the management and prevention of fires. This study demonstrates that artificial intelligence can significantly improve the prediction and management of wildfires in Algeria, contributing to the reduction of human and material losses.

Keywords: predictive model, artificial intelligence, forest fires

Introduction générale

Les incendies de forêt constituent une menace naturelle importante, mettant en danger l'environnement, la biodiversité et les vies humaines. Ces catastrophes, exacerbées par le changement climatique et l'activité humaine, sont de plus en plus étendues, brûlant presque deux fois plus de surface arborée qu'il y a 20 ans. Selon des recherches de l'Université du Maryland, nous avons calculé que les feux de forêts détruisent désormais 3 millions d'hectares de plus de perte du couvert arboré par an, par rapport à 2001 [63]. L'Algérie n'est pas épargnée par ce fléau. Avec une superficie forestière d'environ 4,1 millions d'hectares, le pays est particulièrement vulnérable aux incendies de forêt. En 2021, les incendies en Algérie ont ravagé plus de 100 000 hectares de forêts, causant des pertes humaines et matérielles considérables [64]. Cette situation critique pousse les chercheurs, les gouvernements et les organisations nationales à chercher des solutions efficaces pour lutter contre ce phénomène.

Les nouvelles technologies telles que l'intelligence artificielle et l'apprentissage automatique, jouent un rôle important dans le suivi et la prévention des feux de forêts. En raison de son importance effective dans l'accomplissement rapide de nombreuses tâches et la réduction de nombreux efforts humains. En exploitant des modèles sophistiqués de données climatiques, de végétation, de terrain et de comportement humain, ces technologies permettent de prévoir les zones à risque et de mettre en place des stratégies de prévention proactives.

Notre étude se concentre spécifiquement sur la région de Bejaïa en Algérie, une zone particulièrement sujette aux incendies en raison de sa végétation dense et de son climat méditerranéen. En utilisant des techniques avancées, l'intelligence artificielle et l'apprentissage automatique, nous visons à développer un système prédictif capable d'identifier les zones à haut risque

Notre mémoire est organisé comme suit :

Le premier chapitre aborde les aspects fondamentaux des incendies de forêt pour mieux comprendre ce phénomène qui présente. En mettant en évidence la problématique et l'objectif.

Le deuxième chapitre introduit l'analyse prédictive par l'apprentissage automatique comme méthodes de prévention des feux de forêt. Nous examinons d'abord, l'analyse prédictive et expliquerons son fonctionnement. Ensuite, nous aborderons le rôle important de l'intelligence artificielle, dans ce domaine, et présenterons les concepts de l'apprentissage automatique et sa caractéristique. Nous établirons la relation entre l'analyse prédictive et l'apprentissage automatique. Ce chapitre se conclura par une étude des travaux liés, accompagnée d'une analyse comparative des différentes approches existantes.

Dans le troisième chapitre, nous détaillerons la conception de notre système prédictif. Nous commencerons par la méthodologie de conception de jeux de données. Nous entamons par la suite une description détaillée de l'approche et l'architecture de notre modèle prédictif,

en expliquant les étapes de sa conception et son fonctionnement. Enfin, nous aborderons la partie conceptuelle de l'indice de risque, qui servira à visualiser et interpréter les résultats de notre modèle.

Ce dernier chapitre couvre les aspects techniques de l'implémentation pratique de notre système prédictif. Nous décrirons les outils et technologies utilisés pour sa réalisation et présenterons l'interface utilisateur du système. Nous partagerons les résultats et l'évaluation des expérimentations que nous avons menées et analyserons et décrivant l'exploitation des résultats obtenus

Enfin, une conclusion générale démontrant l'accomplissement de notre objectif en construisant un système prédictif basé sur l'intelligence artificielle pour prédire les incendies de forêt. Nous avons également présenté nos perspectives futures pour le développement de ce projet.

Chapitre 1

Les feux de forêt

1.1 Introduction

Les incendies de forêt sont une préoccupation mondiale en raison de leur impact dévastateur sur l'environnement, les habitats naturels et les populations locales. Dans ce chapitre, nous examinons de manière approfondie les incendies de forêt, y compris leurs types, causes, les facteurs qui influent sur leur propagation, les différentes méthodes de prévention.

1.2. Incendies de forêt

Les incendies de forêt, également connus sous le nom de feux de végétation, sont caractérisés par sa surface minimale de 0.5 hectare, où au moins une partie des étages arbustifs ou arborés est détruite. Ces sinistres nécessitent trois éléments essentiels pour se développer : un combustible, un comburant et une source externe d'énergie [7], comme monter dans la figure 1.



Figure 1 : Les trois facteurs qui conditionnent le phénomène feux de forêt [1].

1.3 Types d'incendies de forêt

Selon les caractéristiques des végétaux et les conditions climatiques, quatre types principaux de feux de forêt se distinguent [2] :

- Feux de profondeur (sol) : se propagent sous la surface sans flammes visibles.
- Feux de surface : brûlent les strates basses avec rapidité et chaleur.
- Feux de cime : se déplacent en hauteur avec une propagation rapide.
- Sautes de feu (braises) : les plus graves, brûlant surface et cimes avec des foyers secondaires.

1.4 Facteurs influents dans la propagation du feu

Les caractéristiques de la végétation, les conditions météorologiques et les facteurs topographiques sont essentiels pour comprendre le développement et la propagation des incendies de forêt. La quantité d'eau présente dans la végétation [3], les conditions atmosphériques telles que la température et la force du vent [2] ainsi que la configuration du terrain, sont des éléments clés qui influent sur le risque et l'intensité des incendies [4].

1.5 Causes principales des incendies

Dans la section suivante, nous présentons les principales causes des incendies :

1.5.1 Causes naturelles

Trois principales causes se distinguant comme suit [5] :

- Conditions météorologiques extrêmes : Les périodes de sécheresse prolongée et les températures élevées augmentent le risque d'incendie de forêt en asséchant le combustible végétal.
- Foudre : Les éclairs peuvent déclencher des incendies lorsqu'ils frappent des zones forestières particulièrement sèches.
- Topographie : Les régions montagneuses et escarpées sont plus susceptibles aux incendies en raison de la facilité de propagation du feu sur les pentes abruptes.

1.5.2 Causes humaines

Parmi les conditions d'apparition de ces incendies, les causes humaines qui ne sont pas bien déterminées et qui représentent l'essentiel des origines des incendies de forêts. Les statistiques officielles algériennes admettent, en effet, que 80% des causes sont inconnues et pour les 20 % restants, elles tendent à proposer des interprétations comme « l'origine naturelle » du phénomène ou bien « les conditions climatiques » dont l'action comme facteur déclenchant est inexistante.

Globalement, on retrouve des incendies dus à des causes involontaires (imprudences). Par exemple, les feux de camp non surveillés ou l'utilisation inappropriée du feu en plein air. Aussi, on a des incendies volontaires par exemple, brûlis agricoles non contrôlés, actes de vandalisme et feux criminels [6].

1.6 Impacts des incendies de forêt

On peut les noter comme suit [7] :

- Émissions de gaz à effet de serre (GES) : Les feux de forêt libèrent d'importantes quantités de carbone dans l'atmosphère, contribuant ainsi au réchauffement climatique.
- Perte de biodiversité : Les feux détruisent les habitats naturels, affectant gravement la faune et la flore.
- Qualité de l'air : Les fumées dégagées par les feux peuvent causer des problèmes respiratoires chez les humains et contribuer à l'augmentation des particules fines dans l'air.
- Impact économique : Les feux affectent les infrastructures et les activités économiques locales, entraînant des pertes financières importantes.

1.7 Stratégies de prévention

Parmi les principales stratégies, nous citons l'aménagement forestier, la surveillance et la détection précoce, le respect des réglementations et des plans de prévention et la sensibilisation publique et l'exploitation des technologies avancées pour prévenir ces incendies [7].

1.8 Problématique

Chaque année, l'Algérie souffre d'une période sombre avec des incendies de forêt qui menacent la sécurité de notre pays, affectant des zones densément peuplées ou des régions éloignées et difficiles d'accès.

L'expérience de toutes ces années prouve que malgré tous les efforts déployés pour les éviter par les services de protection, ce problème génère toujours un taux significatif de dommages. Le pays est toujours menacé par ces incendies de forêt.

Les dégâts et les dangers laissés par ces incendies préoccupent les responsables et les associations du pays et la gestion de ces incendies dépasse souvent les capacités humaines en raison de leur complexité, nécessitant ainsi une approche intégrée intégrant les technologies émergentes.

Pour cette raison, la mise en place d'un système de prédiction des incendies de forêt semble être une très bonne solution pour prévenir les risques pour une meilleure intervention et réduire les dommages.

1.9 Objectifs

L'objectif principal de notre étude est de concevoir et de mettre en œuvre des modèles prédictifs robustes basés sur l'intelligence artificielle. Cela implique l'analyse de données historiques, l'intégration de variables environnementales pertinentes et l'utilisation de techniques avancées de l'apprentissage automatique afin d'améliorer significativement la capacité prédictive des incendies de forêt pour identifier les zones à risque d'incendie pour une future prévention.

La validation de notre système de prédiction des incendies de forêt et la visualisation des risques des zones à identifier à risque se fera par le calcul d'un indice de risque utilisant des systèmes d'information géographique (SIG) (voir annexe A) pour le comparer aux méthodes classiques de prédiction des incendies.

1.10 Conclusion

Les incendies de forêt en Algérie ont constitué un défi majeur pour la préservation de ses écosystèmes forestiers. Au cours des dernières décennies, ces incendies ont montré une tendance à l'augmentation en termes de fréquence et d'intensité. Pour gérer efficacement ce problème croissant, il est essentiel de mettre en place des méthodes de prévention proactives. Parmi les approches les plus efficaces, l'utilisation de l'intelligence artificielle, notamment à travers l'analyse prédictive basée sur l'apprentissage automatique ce qui va être détaillé dans le prochain chapitre.

Chapitre 2

Analyse prédictive

Et

Apprentissage

Automatique

2.1 Introduction

L'analyse prédictive consiste à anticiper des événements à venir en fonction de situations présentes et passées. Pour obtenir des résultats plus précis et pertinents, l'apprentissage automatique intervient en permettant aux systèmes de traiter et d'analyser de grandes quantités de données de manière autonome. Dans ce chapitre, nous présentons un aperçu complet de l'intelligence artificielle et de l'apprentissage automatique, soulignant leur pertinence croissante et leur potentiel significatif dans l'analyse prédictive.

2.2 Analyse prédictive

L'analyse prédictive est capable de déterminer la probabilité d'événements futurs. En utilisant la fouille de données, des branches de l'intelligence artificielle et d'autres méthodes analytiques, elle extrait des informations des grandes bases de données pour prédire les événements futurs.

Dans l'environnement actuel axé sur les données, l'analyse prédictive revêt une importance croissante. Elle permet aux organisations de prédire les tendances futures, de prendre des décisions en analysant les données passées à l'aide de modèles statistiques et de techniques de l'intelligence artificielle. Cela peut conduire à une amélioration des opérations, une optimisation de l'allocation des ressources et une augmentation de la rentabilité [8].

2.3 Intelligence artificielle

L'intelligence artificielle, également connue sous le nom d'intelligence des machines, est une branche de l'informatique qui se concentre sur la construction et la gestion d'une technologie capable d'apprendre à prendre des décisions de manière autonome et à exécuter des actions pour le compte d'un être humain. L'IA n'est pas une technologie unique, il s'agit plutôt d'un terme générique qui inclut tout type de logiciel ou de composant matériel qui prend en charge l'apprentissage automatique [9]. Selon Stuart Russell et le professeur Peter Norvig Approche : "L'intelligence artificielle est le domaine de l'informatique qui traite de la création de systèmes informatiques capables de réaliser des tâches qui nécessiteraient normalement l'intelligence humaine" [10].

2.4 Apprentissage automatique

L'apprentissage automatique est une discipline de l'intelligence artificielle qui habilite les systèmes informatiques à apprendre à partir de données sans être spécifiquement programmés pour chaque tâche. En d'autres termes, il se concentre sur la création d'algorithmes capables de détecter des patrons ou des structures dans les données et de les utiliser pour réaliser des prédictions ou prendre des décisions [11].

Un programme informatique est dit apprendre de l'expérience E par rapport à une tâche T et une mesure de performance P , si sa performance sur T , telle que mesurée par P , s'améliore avec l'expérience E . Une manière mathématique de dire qu'un programme utilise

l'apprentissage automatique est qu'il s'améliore dans la résolution de problèmes avec l'expérience [12].

2.5 Type d'apprentissage automatique

Dans ce qui suit, nous explorerons les différents types d'apprentissage automatique.

2.5.1 Apprentissage automatique supervisé

L'apprentissage supervisé dans le domaine d'apprentissage automatique vise à travailler avec un ensemble de données dont les réponses sont déjà identifiées et catégorisées. Tout comme un enseignant supervisant une classe où les réponses aux questions posées sont connues à l'avance, le processus d'apprentissage ne s'arrête que lorsque les élèves parviennent également à reproduire ces réponses. Dans le contexte des algorithmes d'apprentissage automatique supervisés, l'objectif est d'amener la machine à prédire avec précision les nouvelles données non étiquetées qui lui sont présentées ultérieurement, en se basant sur les modèles appris à partir des données étiquetées [13]. La figure 2 montre un schéma représentatif de l'apprentissage automatique supervisé.




Figure 2 : Apprentissage automatique Supervisé

2.5.1.1 Type d'apprentissage automatique supervisé

L'apprentissage supervisé divise les problèmes en deux catégories principales : la classification et la régression.

Classification

La classification est un processus qui consiste à attribuer des étiquettes ou des catégories aux données en fonction de leurs caractéristiques observées. Un algorithme de classification est entraîné à reconnaître les schémas dans les données étiquetées afin de pouvoir prédire les étiquettes pour de nouvelles données non étiquetées. On trouve des applications variées dans de nombreux domaines, Par exemple, dans le domaine financier, En médecine et santé, il est utilisé pour classer les maladies, aider au diagnostic médical et détecter les fraudes dans les assurances médicales [14].

Régression

La régression est utilisée pour modéliser et prédire des variables continues en fonction de variables indépendantes. L'analyse de régression est une forme de statistique inferentielle, utilisée pour identifier des tendances au sein des données. Les algorithmes de régression en l'apprentissage automatique sont utilisés dans divers domaines tels que la finance pour prédire les prix des actions, le marketing pour analyser les comportements d'achat, la santé pour évaluer le risque de maladies [14].

2.5.1.2 Algorithmes de l'apprentissage automatique supervisé

Dans cette section, nous abordons les différents algorithmes d'apprentissage automatique supervisé :

Régression Linéaire

L'analyse de régression linéaire est utilisée pour prévoir la valeur d'une variable en fonction de la valeur d'une autre, La régression linéaire permet d'ajuster une ligne droite ou une surface qui minimise les écarts entre les valeurs de sortie prédites et réelles. Il existe des calculateurs de régression linéaire simples qui utilisent une méthode « moindres carrés » pour découvrir la ligne la plus adaptée à un ensemble de données appariées. On estime ensuite la valeur de X (variable dépendante) à partir de Y (variable indépendante) [15].

Régression Logistique

Ce type de modèle statistique est souvent utilisé pour la classification et l'analyse prédictive. La régression logistique estime la probabilité qu'un événement se produise, tel que voter ou ne pas voter, sur la base d'un ensemble de données de variables indépendantes. Comme le résultat est une probabilité, la variable dépendante est bornée entre 0 et 1[15].

Machine à vecteurs de support

L'idée principale derrière est de trouver l'hyperplan qui sépare le mieux les différentes classes dans l'espace des caractéristiques. Cet hyperplan est choisi pour maximiser la marge, qui est la distance entre l'hyperplan et les points de données les plus proches de chaque classe, appelés vecteurs de support.

Les SVM peuvent gérer à la fois les données linéairement séparables et non linéairement séparables en utilisant différents types de noyaux qui sont utilisées pour transformer l'espace des données d'entrée dans un espace de dimensions supérieure [15].

Arbre de décision

L'arbre de décision est une méthode utilisée pour la classification et la régression. Ils modélisent les décisions en utilisant une structure arborescente où chaque nœud interne

représente un test sur une caractéristique, chaque branche représente le résultat de ce test, et chaque feuille représente une classe ou une valeur de prédiction. L'algorithme cherche à diviser l'ensemble des données de manière à maximiser la pureté des sous-ensembles résultants [15].

Forêt aléatoire

La forêt aléatoire se compose d'un ensemble d'arbres binaires créés à partir d'une division récursive. Chaque arbre est construit de manière aléatoire en utilisant un échantillon bootstrap des données initiales, ce qui permet de rendre les arbres indépendants les uns des autres et de diminuer la variance de l'ensemble de la forêt. Les arbres sont souvent cultivés en profondeur, bien que la méthode initiale ait préconisé une division basée sur la pureté. [15].

Réseaux de neurones artificiels

Un réseau de neurones artificiel est un modèle d'apprentissage qui comporte plusieurs couches interconnectées. Les données passent par ces couches, subissant des transformations, pour produire une sortie finale. Le réseau apprend en ajustant ses connexions en fonction des erreurs détectées, grâce à un processus appelé rétropropagation. Cela lui permet de minimiser les erreurs au fil du temps [15].

Perceptron multicouche

Un perceptron multicouche (MLP) est un type de réseau neuronal artificiel composé de plusieurs couches de neurones. Les neurones du MLP utilisent généralement des fonctions d'activation non linéaires, permettant au réseau d'apprendre des modèles complexes dans les données. Les MLP sont significatifs dans l'apprentissage automatique car ils peuvent apprendre des relations non linéaires dans les données, ce qui en fait de puissants modèles de tâches telles que la classification, la régression et la reconnaissance des modèles. Dans ce tutoriel, nous plongerons plus profondément dans les bases de la MLP et comprendrons son fonctionnement intérieur [60].

2.5.2 Apprentissage automatique non-supervisé

Contrairement à l'apprentissage supervisé, l'apprentissage non supervisé est utilisé pour tirer des conclusions et trouver des tendances à partir de données d'entrée sans étiquettes (ou labels). Cela retourne des résultats étiquetés et fait apparaître des « catégories ». Dans ce cas, il n'y a pas de professeur pour la classe et les étudiants sont laissés à eux-mêmes pour apprendre [16]. La figure 3 montre un schéma représentatif de l'apprentissage automatique non supervisé.




Figure 3 : Apprentissage automatique non-supervisé [72]

2.5.2.1 Type d'apprentissage automatique non supervisé

Les méthodes d'apprentissage automatique non supervisées comprennent le groupement (cluster), l'association et la réduction de la dimensionnalité

Clustering

Est une technique non supervisée qui consiste à regrouper ou à mettre en clusters des points de données. Les techniques courantes de clustering comprennent la technique des k-means, le clustering hiérarchique, le clustering par décalage moyen et le clustering basé sur la densité [16].

Association

L'exploration des règles d'association permet de découvrir des associations et des relations intéressantes parmi de grands ensembles d'éléments de données. Un exemple typique est une analyse basée sur le marché. L'analyse basée sur le marché est l'une des techniques clés utilisées par les grandes entreprises pour montrer les associations entre les articles. Elle permet aux détaillants d'identifier les relations entre les articles que les gens achètent fréquemment ensemble. En analysant un ensemble de transactions, nous pouvons trouver des règles qui prédisent l'occurrence d'un article en fonction des occurrences d'autres articles dans la transaction [16].

Réduction de dimensionnalité

La réduction de la dimensionnalité est le processus de réduction du nombre de variables aléatoires considérées en obtenant un ensemble de variables principales. La plupart des techniques de réduction de la dimensionnalité peuvent être classées en deux catégories : élimination de caractéristiques ou extraction de caractéristiques [16].

2.5.3 Apprentissage semi-supervisé

L'apprentissage semi-supervisé est un problème d'apprentissage qui implique un petit nombre d'exemples étiquetés et un grand nombre d'exemples non étiquetés. Les problèmes d'apprentissage de ce type sont difficiles car ni les algorithmes d'apprentissage supervisé ni ceux d'apprentissage non supervisé ne sont en mesure d'utiliser efficacement les mélanges de données étiquetées et non étiquetées. FIXMATCH une méthode avancée qui combine habilement données étiquetées et non étiquetées, utilisant le pseudo-étiquetage et d'autres techniques pour améliorer les performances des modèles [17]. La figure 4 montre un schéma représentatif de l'apprentissage automatique semi-supervisé.




Figure 4 : Apprentissage automatique semi-supervisé[72]

2.5.4 Apprentissage par renforcement

Est une méthode d'apprentissage qui interagit avec l'environnement en produisant des actions et en découvrant des erreurs. Les essais, les erreurs et les retards sont les caractéristiques les plus pertinentes de l'apprentissage par renforcement. Chaque fois que nous leur transmettons des données, ils apprennent et ajoutent les données à leurs connaissances, qui sont des données de formation. Ainsi, plus qu'il apprend, mieux il est formé et donc expérimenté [18]. La figure 5 montre un schéma représentatif de l'apprentissage automatique par renforcement.




Figure 5 : Apprentissage par renforcement [72]

2.5.5 Apprentissage ensembliste

L'ensemble Learning est une approche puissante qui consiste à combiner plusieurs modèles d'apprentissage pour obtenir des prédictions plus précises et robustes. Cette méthode repose sur le principe que l'agrégation des prédictions de multiples modèles peut souvent surpasser les performances d'un seul modèle. Parmi les techniques populaires d'ensemble Learning. On cite le boostning , le bagging et le sclaling.

Boosting :

Le Boosting implique la construction d'un système où les classifieurs sont utilisés de manière séquentielle. Chaque classifieur successif se concentre sur les erreurs des prédécesseurs, réduisant ainsi l'ensemble des classes possibles pour un objet à classer [19].

Bagging

Le Bagging repose sur l'idée d'organiser en parallèle un ensemble de classifieurs experts. Chaque classifieur individuel produit une sortie simultanée, et l'ensemble de ces sorties est fusionné pour produire une décision finale [19].

Scaling

Une pratique essentielle en Ensemble Learning est le scaling des données. Cette étape consiste à normaliser les valeurs des caractéristiques pour garantir une convergence plus rapide et des performances optimales des modèles [19].

2.6 Analyse prédictive et apprentissage automatique

La prédiction, dans le domaine de l'analyse de données et d'apprentissage automatique, consiste à estimer ou anticiper la valeur d'une variable cible en se basant sur des données d'entrée existantes. Cela permet de faire des conjectures sur des événements futurs ou des valeurs inconnues en utilisant des modèles mathématiques construits à partir de données historiques. Les prédictions peuvent varier selon le domaine d'application, tel que la finance, la médecine ou la météo, sont réalisées à l'aide d'algorithmes d'apprentissage automatique qui identifient des modèles et des relations entre les variables. La précision des prédictions dépend de la qualité des données, de la pertinence des variables et de la complexité du modèle utilisé [20].

2.7 Travaux connexes

La prédiction des incendies de forêt est un domaine de recherche essentiel et fascinant, abordé par diverses études pour mieux comprendre ce phénomène et proposer des solutions efficaces. Ces travaux se répartissent en plusieurs catégories, l'utilisation de techniques d'exploration d'images et la télédétection, l'application d'algorithmes d'apprentissage automatique, l'emploi de modèles d'apprentissage profond pour une analyse approfondie, et

enfin l'utilisation d'algorithmes de fouille de données. Chaque approche offre des perspectives complémentaires pour la gestion et la prévention des incendies de forêt.

2.7.1 Prédiction des incendies de forêt à l'aide de l'apprentissage automatique

Dans leur étude, Preeti T et al intitulé par « Forest Fire Prédiction Using Machine Learning Techniques » se sont penchés sur l'utilisation de techniques d'apprentissage automatique pour prédire les incendies de forêt. Leur objectif est de minimiser l'impact environnemental en anticipant les zones à risque. Ils ont utilisé des données météorologiques comme la température, la pluie, le vent et l'humidité, ainsi qu'une technique d'image mining pour enrichir les données. L'étude compare plusieurs algorithmes supervisés comme les arbres de décision, les forêts aléatoires, les SVM et les ANN, montrant que l'optimisation avec RandomizedSearchCV donne les meilleurs résultats. Des analyses préliminaires ont également été effectuées pour mieux comprendre les facteurs météorologiques et préparer les données pour l'analyse [21].

Une Autre étude intitulé par « RVFR: Random vector forest regression model for integrated & enhanced approach in forest fires predictions » propose un nouvel algorithme appelé "Modèle de Régression par Forêt Vectorielle Aléatoire" (RVFR) pour prédire la géolocalisation des incendies de forêt avec une précision élevée sur la période de 2011 à 2020. Elle compare plusieurs algorithmes d'apprentissage automatique comme K-NN, SVM, Régression Linéaire, Lasso, Arbre de Décision et MLP, démontrant que le RVFR surpasse tous ses prédécesseurs avec une variance de 1,0. De plus, cet algorithme utilise une valeur logarithmique de l'intensité lumineuse des feux de forêt pour calculer les résultats [22].

2.7.2 Prédiction des incendies de forêt à l'aide de l'apprentissage profond

Truong et al présentant l'étude intitulé par « Une nouvelle approche basée sur les réseaux de neurones profonds TensorFlow avec l'optimiseur ADAM et le SIG pour la prévision spatiale du danger d'incendie de forêt dans les zones tropicales Tran Xuan » présente une méthode innovante basée sur le modèle TFDeepNN pour prédire le danger d'incendie de forêt dans la province de Phu Yen, Vietnam. Comparé à d'autres modèles de référence tels que RF, SVM et LR, TFDeepNN a démontré une performance supérieure. En utilisant dix facteurs, notamment l'indice de végétation par différence normalisée (NDVI) et l'altitude, le modèle a produit une carte de danger d'incendie précise, révélant des zones à très haut risque et à haut risque qui représentent la majorité des emplacements d'incendies de forêt. Ces résultats offrent des informations pour la planification et la gestion des terres dans la région [23].

2.7.3 Prédiction des incendies de forêt à l'aide de fouille de données (data mining)

L'étude intitulée par «Applying genetic algorithms to set the optimal combination of forest fire related variables and model forest fire susceptibility based on data mining models. The case of Dayu County, China », visait à utiliser des algorithmes génétiques pour sélectionner les variables pertinentes liées aux incendies de forêt et appliquer des méthodes de fouille de données pour construire une carte de susceptibilité aux incendies de forêt dans le comté de Dayu en Chine. Treize variables telles que l'élévation, l'angle de pente, la couverture du sol etc. Ont été analysées les méthodes de "Ruptures Naturelles" et de "Facteur de Certitude" ont été utilisées pour classer et pondérer ces variables. Les résultats ont montré que les modèles optimisés RF avaient les meilleures performances, soulignant l'importance des techniques de sélection de variables dans la modélisation de la susceptibilité aux incendies de forêt [24].

2.7.4 Prédiction des incendies de forêt à l'aide des techniques de télédétection

Cette étude intitulée par « La télédétection dans la prévision des incendies de forêts », présente une méthode de suivi du stress hydrique et de l'inflammabilité des forêts méditerranéennes en utilisant les données infrarouges thermiques du satellite NOAA-AVHRR (évapotranspiration réelle ETR) et les données météorologiques synoptiques (évapotranspiration potentielle ETP). Un indice de stress ($1 - \text{ETR}/\text{ETP}$) peut être calculé quotidiennement. Les résultats de cette méthode, testée durant l'été 1994 sur plusieurs grands massifs forestiers méditerranéens français, montrent que l'indice de stress complète les indices météorologiques actuels de risque d'incendie. De plus, les images NOAA permettent de localiser les zones les plus sèches, où la plupart des incendies se sont déclarés. Cette méthode devrait fournir aux utilisateurs finaux un outil pour mieux adapter et localiser leurs moyens de prévention et de lutte contre les incendies [25].

2.8 Étude comparative

Dans cette section, nous analysons, en détail, les différentes approches utilisées pour la prédiction des incendies de forêt, en mettant en lumière leurs principales caractéristiques et les résultats obtenus. Nous effectuons une étude comparative pour rassembler les propositions les plus significatives des chercheurs, accompagnée d'une synthèse de chaque méthode utilisée. De plus, nous discuterons des résultats obtenus par les systèmes de prévision des incendies de forêt déjà déployés.

Le tableau ci-dessous (tableau 1) résume les principales caractéristiques des approches abordées. Il comporte trois colonnes indiquant les critères de comparaison suivants :

- Approche : désigne l'approche de chaque article.
- Données : spécifie les données utilisées.

- Technique utilisée : désigne les méthodes employées pour la prévision des incendies de forêt.

Approche	Données	Technique utilisée
Apprentissage automatique	Météorologique	SVM, DT, RF, ANN RandomizedSearchCV
RVFR	Historique des feux	RVFR
Apprentissage profond TFDeepNN	Historique des feux NDVI, NDWI, LULC topographie, données météorologique	TFDeepNN
Fouille de donnée	Topographie Couverture de sol, historique des feux, données météorologique, végétation et ces facteurs	DG Genetic Algorithms RF SVM, Ruptures Naturelles et Facteur de Certitude
Télédétection	Infrarouges thermiques et les données météorologiques synoptiques	Technique de télédétection

Tableau 1 : Les caractéristiques des approches abordées

Les techniques et les algorithmes d'intelligence artificielle ont été largement utilisés pour prédire les incendies de forêt. Parmi les méthodes discutées, l'apprentissage automatique joue un rôle critique avec des techniques comme les forêts aléatoires, les SVM, les arbres de décision et les réseaux de neurones artificiels (RNA). Ces algorithmes permettent des prévisions rapides, offrant une grande efficacité de calcul et améliorant la performance et la robustesse des systèmes de prévision.

L'apprentissage profond, en particulier les réseaux neuronaux profonds, est extrêmement efficace pour traiter des données non structurées comme les images et les vidéos. Cette méthode garantit des résultats de haute qualité, mais elle nécessite une puissance de calcul significative et peut être coûteuse, la rendant moins accessible aux petites organisations.

Cependant, ces techniques peuvent être complexes et nécessitent un traitement de grandes quantités de données pour obtenir des résultats précis. Fouille de données est une autre méthode couramment utilisée, facilitant une analyse rapide grâce à diverses techniques statistiques, bien que cela puisse être coûteux en termes de calcul.

Les techniques d'exploration d'images sont particulièrement efficaces pour le traitement de données géométriques et satellitaires. Toutefois, elles nécessitent souvent un prétraitement des données. Ce qui peut réduire l'efficacité globale du système.

Les techniques de télédétection, particulièrement efficaces pour le traitement de données géométriques et satellitaires, sont largement utilisées dans la prévision des incendies de forêt. Elles permettent de surveiller les zones à risque en temps réel et d'obtenir des informations précises sur les conditions environnementales. Toutefois, ces techniques nécessitent souvent un prétraitement des données. Ce qui peut réduire l'efficacité globale du système. Ce prétraitement inclut l'analyse et la correction des images pour éliminer les distorsions et les interférences, garantissant ainsi des données de haute qualité pour la prévision des incendies.

Notre solution consiste à mettre en œuvre un système de prédiction des incendies de forêt basé sur l'apprentissage automatique, en expérimentant des algorithmes d'apprentissage automatique tel qu'arbre de décision, forêt aléatoire, régression logistique, support à vecteur machine et multi couche perceptrons. Ces algorithmes, bien que simples à expliquer, offrent une grande flexibilité et réactivité. Ils permettent d'obtenir des résultats précis, les rendant très approprié pour notre objectif de fournir un système de prévision utile et efficace.

Nous avons également déduit que l'utilisation d'images satellitaires contenant des informations liées aux incendies, obtenues par télédétection, enrichirait notre modèle et améliorerait la précision des prévisions. En intégrant ces données, nous pouvons obtenir une vision plus complète et précise des conditions propices aux incendies, augmentant ainsi l'efficacité de notre système de prévision.

En testant divers modèles, en comparant leurs performances et on choisit les modèles avec les meilleurs résultats. Cette approche nous permet de gérer les incendies de forêt de manière rentable et efficace, renforçant ainsi notre choix de modèle pour la prévision des incendies de forêt.

2.9 Conclusion

Après avoir renseigné à propos de d'apprentissage automatique et leur rôle dans l'analyse prédictive des incendies de forêt, Nous allons maintenant concevoir l'architecture de notre système pour assurer sa robustesse et son efficacité, en détaillant les approches suivies et soulignant l'importance de cette phase pour garantir des performances optimales et une bonne adaptabilité ceci va être présenter dans le chapitre trois.

Chapitre 3
Conception

3.1 Introduction

Les incendies de forêt, de plus en plus fréquents, menacent gravement notre environnement. Pour lutter contre ce phénomène, des systèmes sophistiqués basés sur l'apprentissage automatique ont été développés pour améliorer la classification et la prédiction des incendies de forêt.

Dans ce chapitre, nous allons présenter notre approche, qui consiste à prédire les incendies de forêt en utilisant l'apprentissage automatique. Nous détaillerons la conception de nos jeux de données nécessaire pour l'apprentissage de notre modèle prédictif, ainsi que la conception du modèle lui-même. Enfin, nous décrirons la conception de l'indice de risque qui permet une interprétation claire et utile des résultats fournis par notre modèle intelligent.

3.2 Schéma représentatif de notre système

Dans cette section, nous allons présenter le schéma de notre système de prédiction des feux de forêt, qui décrit ses trois grandes parties : la préparation des données, l'entraînement des modèles et le déploiement. Comme montre la figure 6.




Figure 6 : L'architecture globale du système

3.3 Conception de jeux de données

Nous avons commencé notre méthodologie par le filtrage d'une région d'étude spécifique, plutôt que de considérer l'intégralité de l'Algérie. Cette approche permet une analyse plus approfondie des caractéristiques environnementales homogènes, améliorant ainsi la précision des résultats. Par la suite, nous avons procédé à la collecte et à l'intégration des données filtrées selon les facteurs influençant le déclenchement de feux, pour construire nos jeux de données, garantissant ainsi la qualité et la cohérence de notre ensemble de données.

3.3.1 Présentation et justification de choix de région d'étude

La wilaya de Béjaïa est située au nord-est de l'Algérie dans la région de la Kabylie. Le chef-lieu de la wilaya est la ville éponyme de Béjaïa, est une zone géographique d'une richesse naturelle et d'une diversité environnementale remarquable. Cette localisation est un terrain d'étude privilégié pour comprendre les mécanismes des feux de forêt et développer des stratégies efficaces de prévention et de lutte [26]. La figure 7 montre une carte de Béjaïa.



Figure 7 : Carte de Bejaia [73]

3.3.1.1 Justification par rapport à la situation géographique et au milieu physique

Béjaïa présente une géographie variée et fascinante. Vue depuis la mer Méditerranée, la ville apparaît comme un amphithéâtre entouré de montagnes verdoyantes. La région se caractérise par une diversité de reliefs, comprenant des plaines côtières, des massifs du Bouhatem et le massif du Djurdjura au nord, et au sud le massif de Bousselam et les Babords, est traversée par plusieurs oueds (rivières) du fait d'une forte pluviométrie. Les plus importants oueds sont l'oued Soummam (90 kms), l'oued Agrioun (80 kms), l'oued Djemaa

(46 kms), l'oued Zitouni (30 kms) [26]. Cette diversité crée des écosystèmes forestiers variés mais également des défis uniques en matière de prévention et de gestion des incendies, notamment dans les zones montagneuses difficiles d'accès. Sur le plan géographique ces coordonnées géographiques Latitude : 36°45'21" Nord Longitude : 5°05'03" Est, par rapport au niveau de la mer : 86 m d'environ 3 261 km² [27].

Entourée d'une zone urbaine Béjaïa est limitée par la mer Méditerranée au nord, les wilayas de Jijel à l'est, de Bouira et de Tizi-Ouzou à l'ouest, et les wilayas de Bourdj-Bou-Arréridj et de Sétif au sud. La diversité des sols, des sols sablonneux à sablono-limoneux caractérisent la zone côtière, Des sols limoneux et alluviaux caractérisant la vallée de la Soummam, La zone de montagne qui représente 80% de la superficie totale de la Wilaya, se caractérise par des sols de type siliceux et argilo-calcaire des plaines côtières aux zones montagneuses complète ce tableau géographique complexe mais propice à l'étude des feux de forêt [28].

3.3.1.2 Justification par rapport à la situation météorologique

Béjaïa bénéficie d'un climat méditerranéen, avec des étés chauds et secs propices aux incendies, tandis que les hivers sont doux et pluvieux. Les données climatiques, fournies par la station météorologique locale, révèlent une température moyenne annuelle de 18,13°C, avec des variations saisonnières marquées. Les précipitations qui diminuent à mesure que l'on s'éloigne de la mer atteignent une moyenne de 799,85 mm par an, avec un maximum en décembre et un minimum en juillet. L'humidité reste stable autour de 76 %. Les vents dominants viennent du Nord-Ouest avec une vitesse de 8,8 m/s, affectant la vallée de la Soummam. Cette région montagneuse, caractérisée par des reliefs variés et un climat différencié entre la zone côtière et les zones montagneuses, présente des conditions climatiques qui influent sur les incendies et nécessitent une vigilance particulière lors des saisons sèches [28].

3.3.1.3 Historique des incendies

Béjaïa a été confrontée à des épisodes d'incendies de forêt, mettant en évidence l'importance de comprendre les facteurs déclencheurs, la dynamique des incendies et les meilleures pratiques de prévention et de lutte.

En 15 août 2022 Plusieurs dizaines d'incendies ont été enregistrés en moins d'une semaine. Au moins 20 communes de la wilaya. Les habitants redoutent un nouvel épisode d'incendies similaire à celui du mois d'août 2021 qui est toujours dans les mémoires où des milliers d'hectares de végétation, des habitations et des cultures avaient été détruits par le feu [29].

3.3.2 Données d'étude

Dans cette section nous présentons nos données nécessaires pour notre étude, pour la source de collecte de ces données voir l'annexe B.

3.3.2.1 Données de végétation

Qui sont représentés en données liées à la couverture végétale et des indices liés aux végétations.

Couverture végétale

Les données de végétation représentent la couverture végétale de la région d'étude, incluant différents types de végétation telle que les forêts et les prairies. Ces données permettent d'identifier et d'étudier les zones forestières où il existe une probabilité élevée d'incendie.

Indices liés à la végétation

En complément des données de couverture végétale, nous avons collecté plusieurs indices liés à la végétation pour évaluer la santé et les conditions de la végétation, ainsi que leur susceptibilité aux incendies.

Indicateur de Santé de la Végétation VHI : Illustre la gravité des sécheresses en se basant sur l'état de la végétation et l'influence des températures sur les conditions des plantes.

Indice de stress hydrique ASI: Facilite l'identification précoce des terres cultivées souffrant probablement de stress hydrique (sécheresse).

Indice de végétation par différence normalisée NDVI : Mesure la "verdeur" de la couverture du sol et est utilisé comme indicateur de la densité et de l'état de la végétation.

Indice de précipitations IP : Illustre les volumes cumulés de précipitations.

Ces indicateurs jouent un rôle essentiel dans notre étude. Le VHI et le NDVI nous permettent de comprendre l'impact de la sécheresse et des conditions climatiques sur la santé et la densité de la végétation, ce qui est directement lié au déclenchement potentiel des incendies. De même, l'ASI aide à évaluer la vulnérabilité des zones aux incendies en raison de la sécheresse, tandis que l'indice de Précipitations fournit des informations sur les précipitations locales, contribuant ainsi à une meilleure compréhension des facteurs environnementaux influençant le déclenchement des feux de forêt [61].

3.3.2.2 Données de sol

Les données de sol, y compris les composants physiques, chimiques et biologiques, exercent une influence majeure sur les incendies de forêt. Les sols riches en matière organique sont plus susceptibles de s'enflammer facilement, favorisant la propagation rapide des feux. Ces données nous permettent de mieux comprendre la gravité de la dégradation résultant des incendies [61].

3.3.2.3 Données topographiques

Les données topographiques fournissent une perspective sur les caractéristiques physiques du terrain, telles que l'altitude et la pente. Ces données jouent un rôle essentiel dans la

prévision des incendies de forêt, car elles aident à anticiper la propagation du feu en fonction du relief. Comme montre la figure 8.




Figure 8 : Carte des pentes de Bejaia

3.3.2.4 Données d'occupation humaine

Les données de population ont été intégrées comme un facteur essentiel dans les causes des incendies. Elles fournissent une perspective sur la densité humaine et son impact potentiel sur les incendies forestiers.

3.3.2.5 Données météorologiques

Les données météorologiques, incluant des variables telles que la température, l'humidité et la vitesse du vent et d'autres, sont essentielles pour prédire et comprendre les incendies de forêt. L'historique météorologique et les prévisions à court et long terme permettent d'identifier les périodes de risque accru d'incendie.

3.3.2.6 Données sur l'historique des feux

L'utilisation de l'historique des feux de forêt nous permet de créer des sorties étiquetées pour notre jeu de données, facilitant l'entraînement de nos modèles prédictifs.

3.3.3 Méthode de construction de jeux de données

3.3.3.1 Construction de jeux de données statique

On se basant sur les SIG (voir annexe A) [30], nous avons commencé par des opérations de superposition ou d'intersection entre la couche de division administrative (qui représente la source des données de l'occupation humaine) comme couche source et celle de la végétation comme couche de superposition. Ceci nous permet d'obtenir une nouvelle couche résultante de l'intersection, qui devient la nouvelle source, ainsi que la nouvelle couche de superposition qui représente la composition du sol le résultat soit un ensemble des régions ayant les mêmes caractéristiques.

Ensuite, nous calculons à partir de la couche des pentes du raster (voir annexe A) les données statistiques (moyenne, variance, minimum, maximum) pour chaque région de la couche d'intersection résultante.

3.3.3.2 Construction de jeux de données temporelle

Le jeu de données temporelles doit être conçu pour intégrer les dimensions temporelles des données environnementales et historiques. Chaque région sera associée à un ensemble de dates étend de 2009 à 2022. Par la suite nous avons fait une intersection entre les données météorologique et celle de jeux de données résultats après l'ajoute de la date.

Suivant cela nous avons effectué une jointure entre notre jeu de données résultats et celle de l'historique des feux de forêt, Ensuite nous avons effectué l'intersection avec le jeu de données des indicateurs ASI, NDVI, VHI, PI respectivement et au final nous avons ajouté la colonne de sortie (feux /non-feux).

3.3.3.3 Défis liés au jeu de données

Après la construction de notre jeu de données final, nous avons identifié plusieurs problèmes significatifs. Tout d'abord, nous avons été confrontés à un problème de grand volume de données obtenu, rendant la manipulation des données extrêmement difficile. En parallèle, nous avons également rencontré un déséquilibre important entre les classes de données. Plus précisément, nous avons constaté un écart significatif entre les données contenant des informations sur les feux de forêt et celles ne contenant pas de tels événements.

3.3.3.4 Processus d'élimination de défis

Le déséquilibre des données survient lorsque certaines classes sont représentées de manière disproportionnée dans un jeu de données, avec beaucoup plus d'exemples pour une classe que pour une autre. Cela peut affecter nos résultats prédictifs. Il est effectivement logique de constater un déséquilibre dans les résultats entre les jours où les incendies se produisent et les jours sans incendie, compte tenu de peu fréquent des événements d'incendie par rapport au nombre total de jours dans une année ou une période donnée. Pour résoudre cela, des stratégies sont utilisées pour équilibrer les données lors de la construction du jeu de données et du prétraitement, afin d'améliorer les performances des modèles malgré ce déséquilibre.

Au niveau de construction de jeux de données

Nous avons envisagé tout d'abord à définir la période d'étude. Après avoir analysé les statistiques des feux de forêt et les données historiques, nous avons constaté que ces incendies sont plus probables entre avril et octobre. Cette approche a permis une légère réduction du jeu de données, et puis nous avons pensé à avoir la moyenne hebdomadaire des données météorologiques au lieu des données quotidiennes. Notre analyse des données météo a montré que les variations entre les jours de la semaine sont relativement faibles. Grâce à ces

ajustements nous avons pu réduire significativement le déséquilibre entre les classes par rapport aux données initiales.

Au niveau prétraitement de jeux de données

Nous avons utilisé des techniques de rééchantillonnage telles que le suréchantillonnage de la classe minoritaire (oversampling) ou le sous-échantillonnage de la classe majoritaire (undersampling) et autre technique basée sur la division des données en sous jeux de données équilibrés. Ces techniques visent à équilibrer les proportions des classes dans l'ensemble de données d'entraînement.

Méthode sous-échantillonnage

Le sous-échantillonnage (undersampling) consiste à réduire le nombre d'exemples de la classe majoritaire dans un ensemble de données afin de rééquilibrer les proportions des classes. Le fonctionnement de cette méthode est simple : on effectue la sélection aléatoire des exemples de la classe majoritaire jusqu'à ce que le nombre d'exemples dans cette classe soit égal à celui de la classe minoritaire. Après avoir sélectionné aléatoirement les exemples de la classe majoritaire, on combine ces exemples avec ceux de la classe minoritaire pour former un nouvel ensemble de données équilibré.

Méthode de sur-échantillonnage

Le sur-échantillonnage vise à équilibrer les classes en augmentant le nombre d'instances de la classe minoritaire. Les méthodes de sur-échantillonnage. Tout d'abord, il sélectionne aléatoirement une instance de la classe minoritaire dans l'ensemble de données déséquilibré. Ensuite, il identifie les k voisins les plus proches de cette instance dans l'espace des caractéristiques, généralement mesuré par une distance euclidienne. Une fois les voisins identifiés, il crée des exemples synthétiques en combinant l'instance initiale avec une proportion aléatoire du vecteur différence entre l'instance initiale et son voisin [31].

Création de sous jeux de données équilibrés

Pour traiter le déséquilibre des classes dans notre jeu de données, nous avons créé des plusieurs sous jeux de données équilibrés. De tel sorte à prendre pour chaque sous data tous les échantillons de sortie feux et une partie aléatoire des échantillons de sortie non feux.

Algorithme 2 Construction de Sous-données**Entrée** : dataSet**Sortie** : sousDatas**Début**sousDatas $\leftarrow$ liste_videdataSetFeux $\leftarrow$ filtrer (dataSet, 'sortie', 'Feux')dataSetNonFeux $\leftarrow$ filtrer (dataSet, 'sortie', 'non-feux')**Pour** i allant de 1 à nombre_sous_data **faire** dataNonFeuRandom $\leftarrow$ échantillon_aléatoire(dataSetNonFeux, taille(dataSetFeux)) sousData_i $\leftarrow$ concaténer (dataSetFeux, dataNonFeuRandom)

Ajouter (sousDatas, sousData_i)

Fait

Retourner sousDatas.

Fin*Algorithme 1 : Création des sous jeux de données équilibrés*

3.3.3.5 Algorithme explicatif pour la méthode de construction de jeux de données

Algorithme 1 Construction de jeux de données

Entrée: Dataset_static, Dataset_meteo, Dataset_histFire, Dataset_IndicatorVeg

Sortie : Dataset_Finale

Debut

dateList ← liste_de_dates_depuis('2009/04/01' jusqu'à '2022/10/31')

Pour chaque zone dans base_de_données_statique **faire**

 | Zone ['Date'] ← dateList

Fin Pour

Dataset_Temporal ← Intersection (Dataset_static, Dataset_meteo, Sur 'Date')

Dataset_Temporal ← Joindre (Dataset_Temporal, Dataset_histFire, Sur 'géométrie')

Pour chaque entrée dans Dataset_Temporal **faire**

 | **Si** entrée ['attribut_fire'] n'est pas NULL et non ((entrée['Date'] - 7 jours) < Entrée ['Date_fire'] <= entrée ['Date']) **alors**
 | Entrée ['attribut_fire'] = NULL

 | **Fin Si**

Fin Pour

Dataset_Temporal ← Intersection (Dataset_Temporal, Dataset_IndicatorVeg, Sur 'Date')

Pour chaque entrée dans Dataset_Temporal **faire**

 | **Si** entrée ['attribut_fire'] est NULL **alors**
 | Entrée ['sortie'] ← 0

 | **Sinon**

 | Entrée ['sortie'] ← 1

 | **Fin Si**

Fin Pour

Dataset_Finale ← Dataset_Temporal

Retourner Dataset_Finale

Fin

Algorithme 2 : Construction de nos jeux de données

3.4 Modèles prédictifs

Dans cette section, nous examinerons la conception et le développement de divers modèles prédictifs pour la prévention et la gestion des incendies de forêt. Nous couvrirons différentes approches et algorithmes de l'apprentissage automatique, en expliquant leurs principes de fonctionnement.

3.4.1 Support à vecteur machine

Les SVM sont des algorithmes de classification, qui cherchent à trouver l'hyperplan qui sépare le mieux les différentes classes tout en maximisant la marge entre les échantillons les plus proches de chaque classe. On peut appliquer SVM sur des données linéairement séparables ou pas. Pour notre cas ils sont non linéairement séparables.

Dans le cas où les données sont non linéairement séparables, la force des SVM réside en un changement de dimension. Ainsi les données vont être projetées dans un espace de plus grande dimension ce qui va augmenter leur séparabilité.

Ces méthodes reposent sur deux idées clés : la notion de *marge maximale* et la notion de *fonction noyau*. La marge maximale est la frontière de séparation des données qui maximise la distance entre la frontière de séparation et les données les plus proches (i.e. qui maximise la marge). Une fonction noyau est une sorte de transformation qui projette les données de leur espace d'origine vers un espace transformé, dans l'espoir de rendre les données plus linéairement séparables. Parmi les noyaux utilisés dans notre étude : le noyau polynomial, et le noyau gaussien [32]. Comme montre la figure 9.

L'équation de noyau est la suivante:

$$k(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle$$

Le noyau est une fonction possède les propriétés suivantes:

- Positivité : $k(x_i, x_j) \geq 0$
- Symétrie : $k(x_i, x_j) = k(x_j, x_i)$
- inégalité de Cauchy-Schwartz : $k(x_i, x_j) \leq \|x_i\| \cdot \|x_j\|$

Le noyau gaussien est particulièrement adapté à notre problématique car nos données ne sont pas linéairement séparables. Le noyau gaussien utilise une fonction exponentielle qui permet de transformer les données en un espace où un hyperplan linéaire peut être trouvé. Ce noyau est défini comme suit :

$$K(x,y)=\exp(-\gamma\|x-y\|^2)$$

Où γ est un paramètre qui contrôle l'influence d'un seul exemple d'apprentissage. Une valeur de γ élevée implique que chaque exemple d'apprentissage a une influence plus petite, ce qui peut permettre de capter des structures locales complexes dans les données.

Un autre paramètre essentiel dans les SVM est la valeur de régularisation. Ce paramètre contrôle le compromis entre maximiser la marge et minimiser l'erreur de classification sur l'ensemble d'entraînement.

Ainsi, pour notre modèle prédictif, nous avons choisi le noyau gaussien en raison de la non-linéarité des données, et nous avons opté pour une valeur de régularisation élevée pour gérer la complexité et la grande dimensionnalité de notre jeu de données.




Figure 9 : Support à vecteur machines

3.4.2 Arbre de décision

Un arbre de décision est un algorithme d'apprentissage supervisé. L'algorithme CART est utilisé pour la construction des arbres de décisions. Cet algorithme produit un arbre binaire, à chaque nœud, l'algorithme choisit le "meilleur" attribut et seuil pour partitionner les données en deux ensembles. Le choix du meilleur attribut et seuil se fait sur la base de l'impureté et le gain d'information. L'impureté peut être définie comme une chance d'être incorrecte dans la prédiction du Cmax pour une instance donnée. L'arbre de décision prédit une valeur continue, de ce fait nous utilisons comme formule d'impureté, l'erreur quadratique moyenne MSE (mean squared error). MSE mesure la moyenne des carrés des erreurs, est calculé avec la formule suivante :

$$MSE(D_j) = \left(\frac{1}{n_j}\right) * \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Où : D_j est le dataset du nœud j , y_i la valeur de la mesure i , $\hat{y}_i$ la valeur prédite correspondante, N_j est le nombre d'instance du dataset D_j .

Le gain d'information (IG) permet de trouver le meilleur attribut et le meilleur seuil qui réduira le plus cette impureté. Pour calculer le gain d'informations à minimiser, on utilise l'équation suivante :

$$IG(D_p, a_j) = MSE(D_p) - \frac{N_{droit}}{N} MSE(D_{droit}) - \frac{N_{gauche}}{N} MSE(D_{gauche})$$

Où : D_p est le dataset du nœud père, a_i est l'attribut utilisé pour la division, D_{droit} est le dataset du nœud fils droit, D_{gauche} est le jeux de données du nœud fils gauche, N_{droit} est le nombre d'instances au niveau du fils droit, N_{gauche} est le nombre d'instances au niveau du fils gauche, N est le nombre total d'instances [33]. La figure 10 montre un exemple d'arbre de décision dans le contexte de notre étude.

L'un des hyper-paramètres principaux dans la construction des arbres de décision est le paramètre de profondeur de l'arbre. Nous avons cherché à trouver un équilibre entre la capacité de l'arbre à saisir des relations complexes entre les caractéristiques tout en évitant le sur-ajustement.




Figure 10 : Arbre de décision

3.4.3 Régression logistique

La régression logistique est un algorithme d'apprentissage automatique utilisé pour prédire la probabilité qu'une observation appartienne à l'une des deux classes possibles (feux ou pas de feux).

Soit $X = \{x_1, x_2, \dots, x_n\}$ n variables explicatives (nous variables environnementales, topographiques et météorologiques).

La régression logistique a pour objectif de trouver une fonction h telle que nous puissions calculer :

$$y = \begin{cases} 1 & \text{si } h(X) \geq \text{seuil} \\ 0 & \text{si } h(X) < \text{seuil} \end{cases}$$

On comprend donc qu'on attend de notre fonction h qu'elle soit une probabilité comprise entre 0 et 1, paramétrée par $\beta_0, \beta_1, \dots, \beta_n$ à optimiser et que le seuil que nous définissons correspond à notre critère de classification, généralement pris comme valant 0.5 [34].

La fonction qui remplit le mieux ces conditions est la fonction sigmoïde, définie sur $\mathbb{R}$ avec des valeurs dans $[0,1]$. Elle s'écrit de la manière suivante :

$$h(x) = \text{sig}(z) = \frac{1}{1 + e^{-z}}$$

$$\text{Où } z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n.$$

La figure 11 montre la courbe de la fonction sigmoïde.




Figure 11 : la fonction sigmoïde [45]

Pour optimiser les paramètres $\beta_0, \beta_1, \dots, \beta_n$, nous devons définir une fonction coût qui mesure l'erreur entre les prédictions du modèle et les valeurs réelles. Dans la régression logistique, la fonction coût utilisée est la fonction de perte logistique (log-loss), qui est définie comme suit :

$$J(\beta) = m^{-1} \sum_{i=1}^m [y(i) \log(h(x(i))) + (1 - y(i)) \log(1 - h(x(i)))] \quad [35]$$

Où :

- m est le nombre d'exemples d'entraînement,
- $y(i)$ est la valeur réelle de la classe pour l'exemple i ,
- $h(x(i))$ est la probabilité prédite que $y(i)=1$.

Cette fonction coût est choisie parce qu'elle est convexe, ce qui facilite l'optimisation à l'aide de méthodes comme la descente de gradient.

Parmi les paramètres que nous avons configurés pour minimiser la fonction coût $J(\beta)$, nous avons utilisé deux solveurs différents. L'un garantit la gestion des ensembles de données de grande taille et à haute dimension de manière efficace, et offre un temps de calcul raisonnable même pour des ensembles de données volumineux. L'autre permet une convergence rapide vers la solution optimale, ce qui en fait un bon choix pour les ensembles de données de petite à moyenne taille avec un nombre modéré de caractéristiques. Nous avons sélectionné ces solveurs en fonction des spécificités de nos jeux de données et des techniques que nous utilisons.

En plus, un paramètre de régularisation est ajouté à la fonction coût pour pénaliser les grands coefficients, évitant ainsi le sur-apprentissage (overfitting). Pour notre modèle, nous avons utilisé une régularisation, qui permet d'ajouter une somme des carrés des coefficients à la fonction de coût, permettant une meilleure généralisation. Qui est représenté comme suit:

$$\lambda \sum_{j=1}^n \beta_j^2$$

Enfin, nous avons adapté le paramètre de tolérance, qui représente un critère d'arrêt pour l'algorithme d'optimisation. Si les changements dans la fonction coût entre les itérations sont inférieurs à cette tolérance, l'algorithme s'arrête.

3.4.4 Réseau de neurones multicouches

Les réseaux de neurones multicouches, est un type de réseau de neurones artificiels, qui constitués de couches de nœuds, ou neurones artificiels : La première couche est appelée input layer ou couche d'entrée, le dernier output layer ou couche de sortie, et les couches qui se situent entre les deux sont appelées hidden layers ou couches cachées .Comme montre la figure 12.




Figure 12 : réseau de neurones multicouche

Chaque couche effectue une fonction spécifique, et plus le réseau est complexe, plus il y a de couches. Les neurones reçoivent des informations sous forme d'entrées numériques, combinées avec un biais et un ensemble de poids pour produire une seule sortie. Parmi les algorithmes de réseaux de neurones multicouches, on trouve les perceptrons multicouches qui se composent de 3 étapes : la propagation avant, la rétro-propagation de l'erreur observée, et la mise à jour des paramètres du modèle [36].

Propagation avant : Les données sont introduites dans le réseau, se propageant de couche en couche jusqu'à ce que la sortie finale soit produite par la couche de sortie.

Rétro-propagation : La sortie calculée est comparée à la sortie réelle connue, modifiant les poids pour minimiser l'erreur entre ces sorties.

Mise à jour des poids : Pour chaque couche, une fonction d'activation est appliquée pour introduire de la non-linéarité dans le modèle et permettre au réseau de capturer des relations complexes dans les données.

Algorithme 3 formation des perceptrons multicouches avec rétro-propagation

Tant que (Condition d'arrêt non satisfaite) Faire
--

Choisir un échantillon ;

Calculer la sortie du réseau ;

Calculer l'erreur quadratique E^2

Si ($E^2 > \xi$) Alors

Corriger les poids de la couche de sortie ;

Corriger les poids des couches cachées ;
--

Fin Si

Fin Tant que

Algorithme 3 : Formation des perceptrons multicouches

- La condition d'arrêt pouvant être: le nombre d'itérations fixé est atteint ou bien - le réseau répond correctement à tous les échantillons
- Le choix d'un échantillon pouvant être : - tirage aléatoire d'un échantillon - en séquence ; chacun son tour
- Calculer l'erreur quadratique $E^2 = \sum (s_i - d_i)^2$; d_i : le vecteur de sortie désiré ; s_i : le vecteur de sortie obtenu ou calculé.
- Réponse correcte $\Leftrightarrow E^2 = \sum (s_i - d_i)^2 \leq \xi$; ξ à choisir [37].

Parmi les paramètres clé a configuré pour l'amélioration de comportement de ce modèle. Nous citons :

Le nombre de couche, nous avons choisi un nombre de couches en fonction de la complexité des relations que nous supposons dans nos données.

Le solveur (la fonction d'activation) est l'algorithme utilisé pour optimiser les poids du réseau de neurones. Différents solveurs ont des caractéristiques et des performances différentes. Nous avons choisi un solveur en fonction de la taille de notre ensemble de données, de la complexité du modèle et de la rapidité de convergence.

Le nombre d'itérations. Nous avons choisi une valeur adéquate pour le nombre maximal d'itérations afin de garantir la convergence de l'algorithme tout en évitant un temps de calcul excessif de même pour la régularisation pour éviter le sur-apprentissage

3.4.6 Modèles ensemblistes

Dans notre étude, nous avons utilisé des techniques ensemblistes pour améliorer les performances des modèles prédictifs. Les modèles ensemblistes combinent plusieurs modèles de base pour obtenir une meilleure précision et plus grande robustesse. Nous nous sommes concentrés sur deux principales approches : le bagging et le boosting. Pour le bagging, nous avons opté pour Random Forest et Bagging Classifier. Pour le boosting, nous avons utilisé AdaBoost et XGBoost [38]. Parmi les paramètres importants permettant de contrôler le comportement de ces modèles ensembliste : le nombre d'estimateurs, qui détermine la diversité et la puissance du modèle

3.4.5.1 Méthodes basées sur le bagging

Le bagging (Bootstrap Aggregating) est une méthode qui crée plusieurs versions d'un modèle en utilisant des échantillons différents de l'ensemble de données d'entraînement. Chaque modèle est ensuite entraîné indépendamment, et les prédictions finales sont obtenues par vote majoritaire.

Donc, en supposant que nous avons N échantillons *bootstrap* (approximations de N ensembles de données indépendants) de taille B notée :

$$\{z_{11}, z_{21}, \dots, z_{B1}\}, \{z_{12}, z_{22}, \dots, z_{B2}\}, \dots, \{z_{1N}, z_{2N}, \dots, z_{BN}\}$$

$$Z_b^n = b - th \text{ Observation de l'échantillon } n\text{-th bootstrap [39].}$$

Nous pouvons adapter N modèles de base (apprenants faibles) presque indépendants (un sur chaque ensemble de données):

$$w_1(\cdot), w_2(\cdot), \dots, w_N(\cdot)$$

Puis nous les agrégeons de tels sorts que la classe générée par chaque modèle peut être considérée comme un vote et la classe qui reçoit la majorité des votes est renvoyée par le modèle d'ensemble. C'est ce qu'on appelle le vote dur (hard voting). Toujours pour un problème de classification, on peut aussi considérer les probabilités de chacune des classes renvoyées par tous les modèles, faire la moyenne de ces probabilités et garder la classe avec la probabilité moyenne la plus élevée. C'est ce qu'on appelle le vote mou (*soft-voting*). Les moyennes ou les votes peuvent être simples ou pondérés si des pondérations pertinentes peuvent être utilisées. Comme montre la figure 13.

$$S_n(\cdot) = \frac{1}{N} \sum_{n=0}^N w_n(\cdot) \text{ Moyenne simple pour le problème de régression}$$

$sN(\cdot) = \arg_k \max[\text{card}(n | w_n(\cdot) = k)]$ vote à la majorité simple, pour problème de classement




Figure 13 : Méthode bagging

Forêt Aléatoire

La forêt aléatoire est une technique ensembliste qui combine plusieurs arbres de décision. Chaque arbre est construit sur un échantillon aléatoire des données d'entraînement et utilise un sous-ensemble aléatoire des caractéristiques. Nous avons adopté le paramètre de la profondeur maximale des arbres individuels en plus que celui de nombre d'estimateur (arbres), qui influe sur la complexité et la capacité du modèle à s'adapter aux données. En combinant les prédictions de chaque arbre, la forêt aléatoire améliore la précision et la capacité de généralisation par rapport à un seul arbre de décision.

Bagging Classifier

Le Bagging Classifier est une méthode ensembliste générale qui peut être appliquée à divers modèles de base. Comme pour Random Forest, plusieurs modèles de base sont entraînés sur des échantillons bootstrap. Cependant, le Bagging Classifier n'est pas limité aux arbres de décision et peut être utilisé avec d'autres modèles, comme dans notre cas nous avons l'utiliser avec la régressions. Les prédictions des modèles de base sont combinées par vote majoritaire.

3.4.5.2 Méthodes basées sur le boosting

Le boosting est une méthode qui crée une série de modèles de base, où chaque modèle corrige les erreurs du modèle précédent. Les modèles sont combinés de manière pondérée pour former une prédiction finale. Comme montre la figure 14.




Figure 14 Méthode boosting

AdaBoost

Adaboost est une méthode d'apprentissage ensembliste qui construit un modèle fort en agrégeant N modèles faibles de manière itérative pour notre cas nous avons utilisé la régression logistique. Initialement

$S_n(.) = \frac{1}{N} \sum_{n=0}^N c_n \times w_n(.)$ Où les c_n sont des coefficients et les w_n sont des modèles de base

Toutes les observations ont un poids égal, et Adaboost ajuste un modèle faible pour minimiser l'erreur sur ces poids. Ensuite, Adaboost calcule un coefficient de mise à jour basé sur la performance du modèle faible, pondérant ainsi son importance dans le modèle global. Le modèle faible est ajouté au modèle fort en fonction de ce coefficient. Les poids des observations sont mis à jour pour la prochaine itération, en augmentant ceux des observations mal prédites. En répétant ces étapes, Adaboost construit un modèle fort en se concentrant sur les erreurs et en accordant plus d'importance aux modèles faibles performants, aboutissant à un modèle final robuste et précis.

Autrement dit, on définit de manière récurrente les (s_n) tels que :

$$S_n(\cdot) = S_{n-1}(\cdot) + c_n \times w_n(\cdot)$$

Où c_n et w_n sont choisis de sorte que s_n soit le modèle qui s'adapte le mieux aux données d'apprentissage et donc, c'est la meilleure amélioration possible par rapport à s_{n-1} . On peut alors noter :

$$(c_n, w_n(\cdot)) = \arg_{c, w(\cdot)} \min E(s_{n-1}(\cdot) + c_n \times w_n(\cdot)) = \arg_{c, w(\cdot)} \min \sum_{n=1}^N e(y_n, s_{n-1}(x_n) + c \times w(x_n))$$

Où $E(\cdot)$ est l'erreur d'ajustement du modèle donné et $e(\cdot, \cdot)$ est la fonction perte/erreur. Ainsi, au lieu d'optimiser "globalement" sur tous les modèles N de la somme, nous approchons

l'optimum en optimisant "localement" la construction et en ajoutant les modèles de base au modèle fort (en construction), un par un [40].

XGBoost

XGBoost (Extreme Gradient Boosting) est une technique de boosting qui utilise des arbres de décision comme modèles de base et optimise la fonction de perte par descente de gradient. XGBoost construit des arbres de décision séquentiellement, en optimisant une fonction de perte par descente de gradient. Pour éviter le sur-apprentissage, XGBoost utilise des termes de régularisation pour pénaliser la complexité des modèles. De même pour le forêt aléatoire nous avons essayé de régler le max de profondeurs des arbres utilisés par XGBoost pour améliorer la performance de ce modèle.

3.5 Cartographier le risque

Dans cette partie, nous avons entrepris le modèle de l'indice de risque et exploré son double usage dans notre étude. D'une part, il nous a permis de comparer les résultats de nos modèles intelligents avec des méthodes statistiques de calcul de l'indice de risque de feux de forêt. D'autre part, il nous a aidés à générer une cartographie du risque qui attribue des niveaux de risque aux zones identifiées comme à risque par notre modèle. Cette cartographie permet une visualisation claire et intuitive des résultats, rendant les prédictions plus compréhensibles et exploitables pour la gestion des feux de forêt.

Nous nous sommes appuyés sur le modèle d'indice de risque A. Dagorne. Ce modèle, largement utilisé dans le domaine de la gestion des risques naturels [41], est conçu pour évaluer le niveau de risque associé à un événement tel que les incendies de forêt. La formulation générale de ce modèle est donnée par l'expression suivante :

$$IR = 5.IC + 2.IH + IM$$

- IR : Indice de Risque de feu de forêt.
- IC : Indice de Combustibilité (facteur lié au combustible).
- IH : Indice d'occupation Humaine (facteur lié à l'activité humaine).
- IM : Indice topo Morphologique (facteur lié au topo morphologie du terrain).

3.5.1 Indice de combustibilité

La végétation est caractérisée par sa combustibilité qui représente son aptitude à propager le feu en se consumant. Elle traduit donc sa façon de se consumer, en libérant des quantités de chaleur plus ou moins importantes. La combustibilité dépend de la structure et des espèces dominantes de la forêt. L'indice de combustibilité (IC) est exprimé par la relation suivante [43] :

$$IC = 39 + 0,23 BV (E1 + E2 - 7,18)[42]$$

- BV : représente le biovolume de la formation végétale.
- E1 : représente les notes de combustibilité pour les ligneux hauts les plus dominants.
- E2 : représente les notes de combustibilité pour les ligneux bas ou les herbacées les plus dominantes.

3.5.2 Indice topo-morphologique

Trois paramètres topographiques interviennent dans ce modèle : la pente qui a une influence considérable sur le taux de propagation, l'exposition d'un versant détermine la direction vers laquelle il est orienté par rapport au soleil et La position dans le versant ou la topo-morphologie pondère l'intensité du feu en fonction de la position sur le relief. Ces trois paramètres sont exprimés dans le modèle de l'indice par l'équation [44] :

$$IM = 3p + (m+e)$$

- P : la pente.
- m : la topo-morphologie.
- e : l'exposition.

3.5.3 Indice d'occupation humaine

Dans la plupart des cas les causes des incendies liés à l'homme restent inconnues, principalement pour éviter délibérément l'attribution de la responsabilité pour les dommages et l'indemnisation des coûts des dommages, deux aspects source de départ de feu et enjeux, Le premier paramètre est basé sur l'impact anthropique sur le proche voisinage forestier sur une profondeur de 100 m, nous supposons que l'être humain exerce une pression sur son proche voisinage forestier. Le deuxième paramètre tient compte des infrastructures routières (routes, pistes, sentiers). Cependant, les éclosions d'incendie sont beaucoup plus fréquentes près des routes et des chemins de parcours des forêts. On adopte le modèle suivant [44] :

$$IH = IV + 2 ID$$

- IV : indice de voisinage.
- ID : indice de présence humaine.

3.6 Conclusion

Dans ce chapitre, nous avons abordé de manière détaillée la conception et l'architecture de notre système, y compris la création de jeux de données et du modèle, ainsi que la méthodologie pour développer une carte de risque qui permet une meilleure interprétation de nos résultats prédictifs. En englobant toutes les approches et méthodes nécessaires pour concevoir une architecture robuste, nous avons facilité l'implémentation de notre système. Nous allons désormais nous concentrer sur l'aspect expérimental. On l'examinant dans le chapitre suivant.

Chapitre 4

Implémentation

4.1 Introduction

Dans ce chapitre, nous détaillerons le processus d'implémentation de notre système prédictif pour les feux de forêt. Nous commencerons par présenter les logiciels et outils utilisés pour développer notre application. Enfin, nous discuterons des résultats obtenus à partir des expérimentations de notre modèle prédictif et de l'indice de risque, en évaluant leur performance et leur pertinence.

4.2 Description de matérielle

Dans notre étude, nous avons utilisé un environnement de travail équipé des caractéristiques suivantes :

- **Processeur** : 1xsingle core hyper threaded Xeon Processors @2.3Ghz i.e(1 core, 2 threads) et Intel(R) Core(TM) i5-8350U CPU @ 1.70GHz 1.90 GHz
- **GPU** : 1xTesla K80 , compute 3.7, having 2496 CUDA cores , 12GB GDDR5 VRAM
- **Mémoire RAM installée** : 12.6 GB et un mois avec 50 GB et 16 GB de ram en locale
- **Système d'exploitation** : Windows 10 64 bits, processeur x64.
- **Disque dur** : 100 GB en plus de 100 GB supplémentaire dans le drive et 250 GB ssd de notre disque locale.

4.3 Description de logicielle



Le logiciel QGIS est un Système d'Information Géographique convivial distribué sous licence publique générale GNU. C'est un projet officiel de la fondation Open Source Géospatial. Intègre de nombreux formats vecteur, raster, base de données et beaucoup de fonctionnalités [46].



Le logiciel ENVI est un logiciel commercial complet de visualisation et de traitements d'images issues de la télédétection. Toutes les méthodes de traitement d'images de corrections géométriques, radiométriques, de classification et de mise en page cartographique sont présentes [47].



Colab est un service hébergé de notebooks Jupyter Ils permettent aux utilisateurs d'écrire et d'exécuter du code Python par étapes, facilitant ainsi les manipulations sur les jeux de données et le développement de modèles d'apprentissage automatique [48].



TensorFlow est une bibliothèque open source de L'apprentissage automatique, créée par google, permettant de développer et d'exécuter des applications de L'apprentissage automatique et de L'apprentissage profond. Cette bibliothèque permet notamment d'entraîner et d'exécuter des réseaux de neurones pour la classification [49].



Scikit-Learn est une bibliothèque open source d'apprentissage automatique qui prend en charge l'apprentissage supervisé et non supervisé. Elle propose également divers outils pour l'ajustement de modèle, le prétraitement des données, la sélection de modèle, l'évaluation de modèle, ainsi que de nombreuses autres utilitaires [50].



Pandas La bibliothèque logicielle open-source Pandas est spécifiquement conçue pour la manipulation et l'analyse de données en langage Python. Grâce à Pandas, le langage Python permet enfin de charger, d'aligner, de manipuler ou encore de fusionner des données [51]




Keras est une bibliothèque d'apprentissage profond qui offre une API claire et cohérente, facilitant ainsi le développement, la recherche et le déploiement de modèles d'apprentissage automatique [52].



Matplotlib est une bibliothèque polyvalente en Python pour créer des visualisations de données. Elle offre des fonctionnalités pour produire des graphiques de haute qualité, statiques ou interactifs [53].



Seaborn est une bibliothèque de visualisation de données en Python basée sur matplotlib. Elle offre une interface haute niveau pour créer des graphiques statistiques attrayants et informatifs [54].



NumPy est une bibliothèque puissante pour les tableaux N-dimensionnels, devenue un standard dans le calcul de tableaux grâce à ses concepts de vectorisation, d'indexation et de diffusion. Elle offre des outils complets pour le calcul numérique, y compris des fonctions mathématiques, des générateurs de nombres aléatoires et des transformations de Fourier [55].



GeoPandas est une bibliothèque open source qui étend les fonctionnalités de pandas pour inclure la prise en charge des données géographiques. Elle implémente les types GeoSeries et GeoDataFrame, permettant de manipuler et d'effectuer des opérations géométriques sur des objets de géométrie shapely directement au sein des structures pandas [56].



HTML (HyperText Markup Language) crée la structure de base d'un site web, utilisant des balises pour marquer le contenu [57].



CSS (Cascading Style Sheets) ajoute du style et de la mise en forme à cette structure, permettant d'ajuster l'apparence des pages web pour différents dispositifs [57].



JavaScript est un langage de programmation de scripts principalement employé dans les pages web interactives [57].



Leaflet est permis les principale bibliothèque JavaScript open-source pour les cartes interactives adaptées elle possède toutes les fonctionnalités de cartographie dont la plupart des développeurs ont besoin [58].



Django est un framework web Python de haut niveau qui encourage le développement rapide et la conception pragmatique et propre, il se charge de nombreuses tâches fastidieuses du développement web, vous permettant ainsi de vous concentrer sur l'écriture de votre application sans avoir besoin de réinventer la roue. Il est gratuit et open source [59].



Python est un langage de script interprété, interactif et orienté objet, de haut niveau. Conçu pour être très lisible, il dispose de moins de constructions syntaxiques que d'autres langages [60].

4.4 Présentation de l'application

Cette application permet le déploiement de notre système prédictif et qui a deux grandes parties d'interfaces tableau de bord et d'autre pour la prédiction.

4.4.1 Page d'accueil et tableau de bord

Description

La page d'accueil ou tableau de bord de l'application affiche les statistiques liées aux feux de forêt. Elle offre une vue d'ensemble des données importantes et des tendances actuelles. Comme montre la figure 19.

Capture d'écran sur l'interface de tableau de bord




Figure19 : Capture d'écran de tableau de bord de l'application

Détails

Statistiques lie aux feux de forêt : Graphiques et tableaux montrant les tendances des incendies, climat ...etc.

Tableau statistique : contient des informations sur le terrain.

4.4.2 Page de prédiction

Description

La page de prédiction permet aux utilisateurs de saisir les informations nécessaires pour générer des prédictions de risques d'incendie. Un formulaire interactif est utilisé pour entrer la période et la zone. Cette section affiche les résultats de la prédiction sous forme de carte interactive utilisant Leaflet, avec une légende indiquant les niveaux de risque. Comme montre la figure 20.

Capture d'écran sur un exemple de formulaire de prédiction :

The screenshot shows the 'Prédictions des feux de forêts' form. It includes a 'Période de Prédiction' section with 'Date debut' and 'Date fin' fields (format mm/dd/yyyy). Below this is a 'Large Select' dropdown menu currently showing 'Region 1'. At the bottom of the form are 'Prédire' and 'Cancel' buttons. A map is visible at the bottom of the screen.

Figure 20 : Capture d'écran d'un exemple de formulaire de prédiction de l'application

Détails

- Période : Sélection de la période pour laquelle l'utilisateur souhaite obtenir une prédiction.
- Zone (facultatif) : Option de saisir une zone spécifique pour affiner la prédiction.

Capture d'écran sur un exemple de résultat de la prédiction :




Figure 20 : Capture d'écran d'un exemple de résultat de prédiction de l'application

Détails :

Carte interactive : Affichage des zones avec des niveaux de risque prédits.

Légende des risques : Couleurs et étiquettes représentant différents niveaux de risque.

Informations supplémentaires : Détails contextuels sur les résultats de la prédiction à la clique.

4.5 Résultats et discussions

Afin de choisir le meilleur modèle d'apprentissage automatique à utiliser comme modèle prédictif, nous avons implémenté les arbres de décision, les réseaux de neurones multicouches, la régression logistique et le SVM. De plus, nous avons utilisés les modèles ensemblistes pour l'amélioration des résultats des modèles précédentes.

4.5.1 Présentation de jeux de donnée

Notre jeu de données est représenté en 4 jeux de données différents contenant plusieurs attributs essentiels pour la prédiction des incendies de forêt.

Jeu de données 1 : jeu de données déséquilibré. Est de taille de 1.6 millions d'instances, avec 3044 instances classées comme feux et le reste classées comme non feux.

Jeu de données 2 : jeu de données équilibre par la méthode de sur-échantillonnage millions Est de taille de 3.2 millions d'instances, avec le même nombre d'instances classées comme feux et non feux.

Jeu de données 3 : jeu de données équilibre par la méthode de sous-échantillonnage. Est de taille de 6 mille d'instances, avec le même nombre d'instances classées comme feux et non feux.

Jeu de données 4 : jeux de données équilibrée. Chaque sous jeu de données est de taille 4 mille instances, avec le même nombre d'instances classées comme feux et non feux

4.5.1.1 Description des attributs

Dans ce tableau ne définissons les attributs de nos jeux de données.

	Attribut	Description
Végétation	GRIDCODE	Globcover cell value
	LCCCODE	Unique LCCS code
Composition de sol	sand % topsoil	Pourcentage de sable dans la couche arable
	silt % topsoil	Pourcentage de limon dans la couche arable
	clay % topsoil	Pourcentage d'argile dans la couche arable
	pH water topsoil	pH de la couche arable mesuré dans l'eau
	OC % topsoil	Pourcentage de carbone organique dans la couche arable
	N % topsoil	Pourcentage d'azote dans la couche arable
	BS % topsoil	Pourcentage de saturation en bases de la couche arable
	CEC topsoil	Capacité d'échange cationique de la couche arable.
	CaCO3 % topsoil	Pourcentage de carbonate de calcium dans la couche arable
	BD topsoil	Densité apparente de la couche arable
	C/N topsoil	Rapport carbone/azote de la couche arable.
Occupation humaine	Population	Nombre de personnes vivant dans la région correspondante
Pente	Moyenne	Moyenne des pentes dans une région
	Min	Min des pentes dans une région
	Max	Max des pentes dans une région
Météorologique	MAX_TEMPERATURE_C	Température maximale enregistrée en degrés Celsius
	MIN_TEMPERATURE_C	Température minimale enregistrée en degrés Celsius
	WINDSPEED_MAX_KMH	Vitesse maximale du vent en kilomètres par heure
	HUMIDITY_MAX_PERCENT	Humidité relative maximale en pourcentage
	PRESSURE_MAX_MB	Pression atmosphérique maximale en millibars
	HEATINDEX_MAX_C	Indice de chaleur maximal en degrés Celsius
	DEWPOINT_MAX_C	Point de rosée maximale en degrés Celsius
	WINDTEMP_MAX_C	Température ressentie maximale due au vent en

		degrés Celsius
	TOTAL_SNOW_MM	Quantité totale de neige en millimètres
	UV_INDEX	Indice UV maximal
	TEMPERATURE_JOURNEE	Température moyenne durant la journée
	TEMPERATURE_NIGHT	Température moyenne durant la nuit
Indice de végétation	VHI	Indicateur de Santé de la Végétation
	ASI	Indice de stress hydrique
	NDVI	Indice de végétation par différence normalisée
	IP	Indice de précipitations
Date	Month	Le mois ou les données temporelle enregistrée
	Day	Le jour où les données temporelle enregistrée
Sortie	Fire	Output

4.5.2 Prétraitement

Le prétraitement des données est une étape essentielle pour améliorer la qualité et la performance des modèles prédictifs. Dans notre étude, nous avons d'abord implémenté les méthodes d'équilibrage décrit dans la phase de conception ensuite nous avons entamé le nettoyage, l'encodage et la standardisation de nos jeux de données

4.5.2.1 Nettoyage des données

Le nettoyage des données consiste à corriger les erreurs, supprimer les doublons et gérer les valeurs manquantes. Tout d'abord, nous avons supprimé les duplications pour éviter les biais dans notre analyse. Ensuite, nous avons imputé les valeurs manquantes en utilisant la moyenne des colonnes concernées avec *fillna* de la bibliothèque *pandas*. Cette approche permet de préserver autant d'informations que possible tout en rendant les données complètes et utilisables.

4.5.2.2 Encodage des données

Les variables catégorielles doivent être converties en valeurs numériques pour être traitées par les algorithmes de d'apprentissage automatique. Nous avons commencé par encoder les codes LCC en valeurs numériques spécifiques. De plus, nous avons transformé la variable cible (feux de forêt) en une représentation binaire, où "Fire" est codé par 1 et "Not Fire" par 0. En travaillant avec '*LabelEncoder*' de la bibliothèque '*sklearn.preprocessing*', ensuite Les informations de date ont été décomposées en caractéristiques distinctes telles que le mois et le jour. Facilitant ainsi leur traitement.

4.5.2.3 Standardisation des données

La standardisation des données est une étape essentielle pour mettre toutes les variables sur une échelle comparable. La standardisation transforme les données pour qu'elles aient une moyenne de 0 et un écart-type de 1. Nous avons utilisé '*StandardScaler*' de '*sklearn.preprocessing*'.

4.5.3 Métriques d'évaluation

Dans cette section, nous présentons les différentes métriques utilisées pour évaluer les performances de nos modèles. Les métriques choisies sont la précision, le rappel, l'exactitude et le F1 score. Chacune de ces métriques offre une perspective différente sur les performances de nos modèles, permettant ainsi une évaluation complète [63].

4.5.3.1 Précision

La précision est une métrique qui mesure la proportion de prédictions positives correctes parmi l'ensemble des prédictions positives effectuées par le modèle. En d'autres termes, elle indique la capacité du modèle à ne pas classer incorrectement un non-incendie comme un incendie.

$$Précision = \frac{TP}{TP+FP}$$

- TP (True Positives) : Nombre de vrais positifs (incendies correctement prédits).
- FP (False Positives) : Nombre de faux positifs (non-incendies incorrectement prédits comme des incendies).

4.5.3.2 Rappel

Le rappel, ou sensibilité, mesure la capacité du modèle à identifier tous les incendies réels parmi l'ensemble des incendies présents dans les données. Il indique la proportion d'incendies correctement prédits parmi tous les incendies réels.

$$Rappel = \frac{TP}{TP+FN}$$

- FN (False Negatives) : Nombre de faux négatifs (incendies non prédits par le modèle).

4.5.3.3 Exactitude

L'exactitude est la proportion de prédictions correctes (positives et négatives) parmi l'ensemble des prédictions effectuées par le modèle. C'est une mesure globale de la performance du modèle.

$$Exactitude = \frac{TP+TN}{TP+FP+FN+TN}$$

- TN (True Negatives): Nombre de vrais négatifs (non-incendies correctement prédits)

4.5.3.4 F1-Score

Le F1 score est la moyenne harmonique de la précision et du rappel. Il offre un équilibre entre les deux métriques, particulièrement utile lorsque les classes sont déséquilibrées. Le F1 score est une mesure robuste de la performance globale du modèle.

$$F1-score = 2 * \frac{P \text{ précision} * Rappel}{P \text{ précision} + Rappel}$$

Pour notre cas et dans le contexte de la prédiction des incendies de forêt, une précision élevée signifie que lorsque le modèle prédit un incendie, il y a une forte probabilité que cette prédiction soit correcte. Cela est nécessaire pour éviter les fausses alertes, qui peuvent entraîner des interventions inutiles et coûteuses.

Un rappel élevé signifie que le modèle est efficace pour détecter les incendies réels, minimisant ainsi le risque de manquer des cas critiques où des interventions seraient nécessaires. Le F1 score permet d'évaluer la capacité du modèle à identifier les incendies tout en minimisant les fausses alertes.

Un F1 score élevé indique que le modèle a une bonne performance globale en termes de précision et de rappel, assurant ainsi un équilibre entre la détection correcte des incendies et la réduction des fausses prédictions.

Enfin, une exactitude élevée indique que le modèle est globalement performant à la fois pour identifier les incendies et pour reconnaître les non-incendies.

4.5.4 Résultat d'évaluation des modèles Prédicatifs

Dans cette partie, nous décrivons les résultats et les discussions concernant l'évaluation de nos modèles prédictifs en utilisant notre ensemble de données.

Avant de commencer l'entraînement des modèles, nous avons divisé nos jeux de données en trois parties, une pour l'entraînement de modèle autre pour la validation et une troisième pour le test et l'évaluation de performance de modèle.

4.5.4.1 Les hyper paramètres à configurer

Ils sont spécifiés comme suit :

- **Noyau** : Définit la fonction utilisée pour transformer les données dans un espace de plus grande dimension.
- **Poids de classes** : Attribue des poids différents aux classes.
- **Nombre d'itérations** : Le nombre d'étapes effectuées lors de l'entraînement d'un modèle.
- **Pénalité** : Ajoute une pénalité aux coefficients du modèle pour éviter le sur-apprentissage.
- **Solver** : L'algorithme utilisé pour résoudre le problème d'optimisation
- **Nombre d'arbres** : Spécifie le nombre d'arbres construits.
- **Profondeur maximale** : Limite la profondeur des arbres de décision.
- **Régularisation** : La régularisation est une technique utilisée pour contrôler la complexité d'un modèle en ajoutant une pénalité aux coefficients.

- **Tolérance** : La tolérance est souvent utilisée dans les algorithmes d'optimisation pour définir un critère d'arrêt.
- **Nombre de couches** : le nombre de couches cachées dans le réseau.
- **Alpha** : régularisation.

Pour sélectionner ces hyper-paramètres, nous avons utilisé une validation croisée. Cette technique permet de diviser notre jeu de données en k sous-ensembles pour notre cas nous avons testé avec un k égale a 5. En entrainant le modèle sur $k-1$ sous-ensembles et le testant sur le sous-ensemble restant. Ce processus est répété k fois, chaque sous-ensemble étant utilisé une fois comme ensemble de test. Les hyper-paramètres ont été choisis en fonction de ces performances. En utilisant la méthode '*stratifiedshuffleplit*' de '*sklearn.model_selection*' [50].

4.5.4.2 L'évaluation

En va examiner, dans cette partie, les résultats de test après l'entrainement des différents modèles avec différents jeux de données.

Jeu de données 1

Dans ce tableau (tableau 2), nous présentons le meilleur résultat d'évaluation des différents modèles d'apprentissage automatique, testé avec le jeu de données 1 déséquilibré et les valeurs des hyper-paramètres lui correspondant.

Algorithmes	Hyper-paramètres		Exactitude	Précision	Rappel	F1-Score
Support à vecteur machine (SVM)	Noyau	rbf	0.81	0.96	0.64	0.77
	Poids classes	(1 ;99)				
Régression logistique (RL)	Nbr Itération	1000	0.83	0.88	0.78	0.82
	Régularisation	0.1				
	Solver	Saga				
	Poids classes	(1 ;99)				
Arbre de décision (DT)	Max profondeur	5	0.81	0.97	0.64	0.77
	Poids classes	(1 ;99)				
Forêt aléatoire (RF)	Nbr Arbres	200	0.75	1.00	0.50	0.67
	Max profondeur	10				
	Poids classes	(1;99)				

Tableau 2 : Résultats d'entrainement avec le jeu de données 1

Discussion

En tenant compte des résultats obtenus dans ce tableau, on peut constater que la régression logistique correspond au modèle avec la meilleure F1 score 0.82 par rapport aux autres modèles. Ce qu'indique que ce modèle est capable de classifier les feux avec un bon équilibre entre la prédiction des vrais incendies et l'évitement des fausses alertes. En second lieu, les modèles SVM et DT montrent des performances presque équivalentes. Enfin, le modèle RF

présente un F1-score moins performant de 0.75. Ce qui va à l'encontre de nos attentes mais reste acceptable, bien qu'il soit le modèle le moins performant parmi ceux évalués.

Jeu de données 2

En utilisant le jeu de données 2, nous présentons le meilleur résultat d'évaluation des différents modèles d'apprentissage automatique testé dans le tableau suivant (tableau 3):

Algorithmes	Hyper-paramètres		Exactitude	Précision	Rappel	F1-Score
Support à vecteur machine (SVM)	Noyau	rbf	0.81	0.77	0.89	0.83
	Régularisation	100				
Régression logistique(RL)	Nbr Itération	1000	0.82	0.76	0.94	0.84
	Régularisation	0.1				
	Solver	Newton-cg				
	Tolérance	1e-4				
Forêt aléatoire (RF)	Nbr Arbres	100	0.89	0.89	0.90	0.89
	Max profondeur	10				
Arbre de décision (DT)	Max profondeur	50	0.77	0.80	0.71	0.75
	Poids classes	(1;99)				
Multicouches perceptrons (MLP)	Nbr couches	9	0.87	0.83	0.93	0.87
	Max itération	1000				
	Alpha	0.0001				
	Solver	adam				
XGBoost (XGB)	Max profondeur	35	0.90	0.90	0.90	0.90
	Nombre d'arbres	100				
	Learning rate	0.1				
AdaBoost : Régression logistique (AB)	Nbr Itération	1000	0.82	0.76	0.94	0.84
	Régularisation	0.1				
	Solver	newton-cg				
	Nbr de modèle	200				
BaggingClassifieur: régression logistique (BC)	Nbr Itération	<u>1000</u>	0.83	0.77	0.93	0.84
	Régularisation	0.1				
	Solver	newton-cg				
	Nbr de modèle	500				

Tableau 3 : Résultat d'entraînement avec le jeu de données 2

Discussion

Les tableaux précédents montrent que le Réseau de Neurones Multicouches perceptrons (MLP) avec un F1-score de 0.87 surpasse la Régression Logistique avec F1-score de 0.84 et le SVM F1-score de 0.83. L'Arbre de Décision a les performances les plus faibles

F1-score de 0.75. Le MLP offre un meilleur équilibre entre précision et rappel tandis que l'Arbre de Décision a un rappel plus faible.

Pour les modèles ensemblistes le tableau montre que XGBoost se distingue avec une exactitude, une précision, un rappel et un F1-score de 0.90, montrant une excellente capacité de généralisation par rapport au modèle de base testés. La Forêt Aléatoire suit de près avec un F1-score de 0.89. Les autres modèles d'ensemble comme AdaBoost et Bagging apportent des améliorations par rapport aux modèles de base, mais ne surpassent pas XGBoost.

Jeu de données 3

Dans ce tableau (tableau 4), nous présentons le meilleur résultat d'évaluation des différents modèles d'apprentissage automatique testé avec le jeu de données 3:

Algorithmes	Hyper-paramètres		Exactitude	Précision	Rappel	F1-Score
Régression logistique (RL)	Nbr Itération	100	0.84	0.80	0.92	0.86
	Régularisation	0.1				
	Solver	saga				
	Tolérance	1e-4				
	Max profondeur	10				
Arbre de décision (DT)	Max profondeur	50	0.85	0.92	0.77	0.84
Multicouches perceptrons (MLP)	Nbr couche	12	0.61	0.98	0.23	0.37
	Max itération	1000				
	alpha	0.0001				
	solver	adam				

Tableau 4 : résultats d'entraînement avec le jeu de données 3

Discussion

Pour ce type de jeu de données, il est justifié de ne pas montrer les résultats de certains modèles en raison de problèmes d'entraînement prolongé sans obtenir de résultats satisfaisants, souvent dus à des limitations de ressources

D'autre part, la Régression Logistique montre les meilleures performances globales avec un F1-score de 0.86, indiquant un bon équilibre entre précision (0.80) et rappel (0.92). L'Arbre de Décision a une précision élevée (0.92) mais un rappel plus faible (0.77). Ce qui se traduit par un F1-score de 0.84. Le Réseau de Neurones Multicouches présente des performances très faibles avec un F1-score de 0.37 malgré une précision très élevée (0.98), dû à un rappel très bas (0.23), indiquant une sur-adaptation possible aux données d'entraînement et une mauvaise généralisation

Jeu de données 4

Dans ce tableau (tableau 5), nous présentons le meilleur résultat d'évaluation des différents modèles d'apprentissage automatique testé avec sous data.

Algorithmes	Hyper-paramètres		Vote majoritaire				Moyenne = 0.4			
			Exact itude	Précision	Rappel	F1-score	Exact itude	Précision	Rappel	F1-score
Support à vecteur machine	Noyau	rbf	0.71	0.88	0.49	0.62	0.71	0.88	0.49	0.71
	Régularisation	1000								
Régression logistique (RL)	Nbr Itération	500	0.83	0.77	0.93	0.84	0.82	0.77	0.93	0.84
	Régularisation	1000								
	Solver	Newton-cg								
Arbre de décision (DT)	Max profondeur	10	0.87	0.89	0.84	0.87	0.87	0.89	0.85	0.87
Multicouches perceptrons (MLP)	Nbr couche	4	0.53	0.52	0.99	0.68	0.53	0.51	0.99	0.68
	Max itération	2000								
	alpha	0.0001								
	solver	adam								

Tableau 5 : résultat d'entraînement avec le jeu de données 4

Discussion

Pour la technique de création des sous jeux de données équilibrés qui nécessite l'entraînement de plusieurs modèles avec différentes sous jeux de données et avoir le vote majoritaire ou par moyenne comme résultats. On peut déduire que le meilleur modèle est l'Arbre de décision avec la meilleure le F1_score (0.87) (pour les deux méthodes de vote). Et pour les autres modèles (DT, SVM), on a aussi de bons résultats. Le MLP est largement inférieur aux autres modèles, en termes de performance globale.

Choix de modèle

En se basant sur les résultats présentés, il est déduit que le modèle prédictif XGBoost entraîné avec le jeu de données avec la méthode de sous-échantillonnage a obtenu les meilleurs résultats comme montrer la matrice de confusion (la figure : 19). Cela est dû à sa simplicité, car il est particulièrement adapté à la gestion d'un grand nombre de caractéristiques, ce qui est un avantage significatif dans notre cas et est facile à entraîner, ne nécessitant pas beaucoup de temps ni de ressources. De plus, il affiche les meilleures métriques de prédiction. Ce qui en fait un choix efficace et peu coûteux en termes de déploiement, ne demandant pas beaucoup d'espace ou de performances machine.




Figure 15 matrice de confusion

4.5.5 Résultat de calcul de l'indice de risque

Nous avons commencé par la génération des trois sous-indices pour le calcul de l'indice de risque des incendies de forêt (Pour visualiser les résultats intermédiaires au niveau de chaque sous-indice voir annexe C).

4.5.5.1 Calcul de l'indice de combustibilité

Le biovolume a été calculé à partir de la carte NDVI en utilisant la formule suivante (voir annexe C) :

$$((NDVI \times 50) + 50) / 100 \times 50$$

Les notes de combustibilité ont été calculées à partir de la carte des types de couverture terrestre dominante et du tableau des notes de combustibilité CEMAGREF (voir annexe C).

En raison de nos limitations d'information, nous avons effectué une simulation où nous classifions chaque type du tableau des notes de combustibilité dans les classes de couverture terrestre dominante.

La carte finale de l'indice de combustibilité consiste en la superposition de la carte de E et la carte de biovolume.




Figure 16 : Carte de l'indice de combustibilité

4.5.5.2 Calcul de l'indice topo-morphologique

À partir d'un Modèle Numérique de Terrain (MNT) et à l'aide d'outils SIG, on a pu extraire la carte des pentes et de l'exposition des versants de Béjaïa (voir annexe C).

On a calculé la carte de la topo-morphologie par l'expression $M = \text{Pente} + \text{DEM}$.

Nous avons obtenu la carte d'IM par calculatrice raster de QGIS.




Figure 17 : Carte de l'indice de topo morphologique

4.5.5.4 Calcul de l'indice humain

Indice humain se base sur deux sous-indices : l'indice de voisinage, proximité des routes.

L'indice de voisinage été calculé à partir des deux cartes : densité de population et d'occupation du sol (on extraire les zone urbaines). Indice de présence humaine (proximité des routes) : En raison de la limite des informations disponibles sur la densité d'utilisation des routes, nous avons envisagé une approche alternative. Nous avons simulé le risque de présence humaine où les routes sont proches du front de forêt. Pour ce faire, nous avons calculé à partir de la carte des routes de Béjaïa et des forêts de Béjaïa, en divisant le réseau routier en tronçons de distance variable. Ensuite, pour chaque tronçon, nous calculons la distance jusqu'à la forêt la plus proche. Cela nous permet d'évaluer le risque associé à la route la plus proche de la forêt. La carte d'occupation humaine a été élaborée par la composition linéaire des deux indices.




Figure 18 : Carte de l'indice de d'occupation humaine

4.5.5.5 Cartographie de risque

Afin de réaliser la carte de l'indice de risque de feu, on a superposé les trois couches d'indice topo-morphologique, d'indice de combustibilité et d'indice d'occupation humaine à l'aide de raster calculatrice de QGIS.




Figure 19 : Carte d'indice de risque

4.5.6 Comparaison entre le modèle intelligent et l'indice de risque statique

Notre modèle prédictif basé sur l'intelligence artificielle excelle grâce à sa capacité à intégrer des données temporelles comme celle météorologique pour des prévisions précises des incendies de forêt, simplifiant l'interprétation avec ses deux derniers et offrant une adaptabilité pratique pour la détection en temps réel. En revanche, l'indice de risque statique, bien qu'il fournisse des pourcentages de risque détaillés, peut manquer de précision en raison de son incapacité à tenir compte des variations temporelles et météorologiques, rendant sa visualisation moins pratique pour une utilisation opérationnelle dans la prévention des incendies.

Ce qui nous conduit à exploiter l'indice de risque statique est son utilité pour l'interprétation des résultats de l'intelligence artificielle en attribuant ce niveau de risque aux zones prédites comme étant à risque. Cela permet une compréhension plus approfondie des prédictions de l'IA en les associant à une mesure spécifique de risque, renforçant ainsi la fiabilité et la pertinence des informations pour une action préventive ciblée dans les zones identifiées comme potentiellement à risque d'incendie.

4.6 Conclusion

Dans ce chapitre d'implémentation, nous avons plongé dans les détails techniques de notre système de prédiction des feux de forêt. Nous avons exploré les aspects logiciels et matériels ainsi que l'interface de notre application utilisée. En outre, nous avons présenté nos expérimentations approfondies et les résultats obtenus qui ont été importants pour le déploiement réussi de notre système de prédiction des incendies de forêt. Ces résultats nous ont permis d'exploiter efficacement notre système pour la prévision future des incendies, ouvrant ainsi la voie à une approche proactive et préventive dans la gestion des catastrophes naturelles.

Conclusion générale

Les incendies ont toujours constitué une menace pour nos forêts. Aujourd'hui, avec le changement climatique en cours, le risque s'aggrave encore. L'intelligence artificielle s'impose progressivement comme un atout majeur dans cette lutte contre les flammes. En combinant puissance de calcul et capacités d'analyse, l'IA offre des solutions prometteuses pour anticiper, détecter et contrôler les incendies de forêt.

Ce projet de fin de cycle nous a permis d'explorer les possibilités offertes par l'apprentissage automatique dans la prédiction des feux de forêt, contribuant ainsi à réduire les risques et les conséquences néfastes des incendies. L'objectif de notre travail de recherche s'est principalement orienté vers l'étude et la mise en œuvre de modèles prédictifs, ainsi que la cartographie du risque en utilisant les Systèmes d'Information Géographique.

Notre démarche s'est articulée autour de quatre grandes parties. D'abord, nous avons effectué une étude environnementale approfondie pour bien comprendre ce phénomène, identifier les facteurs liés au déclenchement des feux et les éléments influençant leur propagation. Ensuite, une recherche approfondie sur l'apprentissage automatique et ses branches, nous a permis de classer notre problème et de sélectionner les algorithmes appropriés pour construire notre modèle. Nous avons également étudié les approches existantes dans la littérature scientifique. Ce qui nous a aidés à comprendre les avantages et les inconvénients de différentes méthodes et à sélectionner les modèles à tester. Par la suite, nous avons conçu un jeu de données en collectant tous les facteurs influençant les feux de forêt, une étape essentielle pour le développement de modèles prédictifs robustes. Nous avons ensuite développé différentes architectures de modèles pour prédire les risques de feux de forêt. Enfin, nous avons présenté notre application et ses différentes fonctionnalités. En implémentant notre conception, nous avons mené une analyse des résultats pour évaluer la performance des modèles entraînés. Ce qui nous a permis de choisir le modèle prédictif le plus performant. Nous avons calculé l'indice de risque et cartographié les résultats de notre modèle prédictif.

Les résultats obtenus sont prometteurs, mais plusieurs perspectives peuvent être envisagées pour améliorer et étendre ce travail. Il serait bénéfique d'explorer de nouveaux modèles d'apprentissage automatique et de combiner plusieurs modèles pour optimiser les performances. L'ajout de nouveaux facteurs tels que les activités humaines spécifiques, affinerait les prédictions ou l'ajout de l'indice de risque calculer comme facteur englobant les 3 facteurs combustible, topo-morphologique et d'occupation humaine. L'optimisation des hyper-paramètres et une analyse spatiale et temporelle plus approfondie pourraient également améliorer l'efficacité des modèles. Enfin, le développement d'une application de suivi en temps réel permettrait de surveiller les feux de forêt et de fournir des alertes précoces, contribuant à une meilleure gestion des risques et à la protection de l'environnement.

Bibliographie

- [1] Le phénomène feux de forêt <https://www.futura-sciences.com/sciences/dossiers/incontournables-feux-forêt-information-prevention-391/page/3/> (consulté le 2 /01/2024).
- [2] Plana, E. ; Font, M. ; Serra, M. ; Chauvin, S. ; Gladiné, J. 2016. Les incendies en forêt, guide pour les journalistes et les médias. Projet eFIRECOM. Edition CTFC.
- [3] Maylan, Doméne. (2002). Les feux de forêt. MINISTÈRE DE L'ÉCOLOGIE ET DU DÉVELOPPEMENT DURABLE (MEDD). Dossier d'information.
- [4] Mauguén G., Lesne P., Petit J.M., Sallé B., Marc F., 2012 : Evaluation du risque méditerranéen. Écologique plantarium.
- [5] OCDE (2023), « Résumé », dans Taming Wildfires in the Context of Climate Change, Éditions OCDE, Paris. DOI (consulté le 13/01/2024)
- [6] (Berchiche, 1986 ; Meddour-Sahar, 2008 ; FAO, 2013).
- [7] Feu de forêt : chiffres, causes, conséquences et prévention Feu de forêt : chiffres, causes, conséquences et prévention (greenly.earth) (consulté le 14 /01/2024).
- [8] Quels sont les enjeux derrière l'analyse prédictive ? <https://www.datasulting.com/articles/analyse-predictive-definition-enjeux/> (consulté le 2 /02/2024).
- [9] Intelligence Artificielle : Définition, histoire, enjeux Intelligence Artificielle : Définition, histoire, enjeux (consulté le 06/03/2024)
- [10] Stuart Russell et Peter Norvig dans leur livre "Intelligence Artificielle: A Modern Approach" 3rd Edition, Pearson, 2021.
- [11] Machine Learning : Définition, fonctionnement, utilisations <https://datascientest.com/machine-learning-tout-savoir> (consulté le 13/02/2024).
- [12] Selon Tom Mitchell, professeur en informatique et en apprentissage automatique à Carnegie Mellon.
- [13] Qu'est-ce que l'apprentissage supervisé ? <https://www.ibm.com/fr-fr/topics/supervised-learning> (consulté le 20/03/2024).
- [14] Explication de la régression et de la classification dans l'apprentissage automatique <https://geekflare.com/fr/regression-vs-classification/> (consulté le 23/03/2024).
- [15] Les algorithmes de Machine Learning supervisés <https://medium.com/> (consulté le 24/02/2024).
- [16] Apprentissage non-supervisé : définition et algorithmes populaires <https://www.journaldunet.fr/intelligence-artificielle/guide-de-l-intelligence-artificielle/1501309-apprentissage-non-supervise> (consulté le 24/02/2024).
- [17] L'apprentissage semi-supervisé : Tout savoir ce qu'il faut savoir <https://datascientest.com/apprentissage-semi-supervise-tout-savoir> (consulté le 16/03/2024).

- [18] Qu'est-ce que l'apprentissage par renforcement ? <https://aws.amazon.com/fr/what-is/reinforcement-learning/> (consulté le 18/02/2024).
- [19] Ensemble learning : définition, fonctionnement et algorithmes <https://www.journaldunet.fr/intelligence-artificielle/guide-de-l-intelligence-artificielle/> (consulté le 22/03/2024).
- [20] Le rôle du Machine Learning dans l'Analyse Prédictive <https://www.voxco.com/fr/blog/le-role-du-machine-learning-dans-lanalyse-predictive/> (consulté le 22/03/2024).
- [21] Preeti T, Dr.Suvarna Kanakaraddi, Aishwarya Beelagi, Sumalata Malagi, Aishwarya Sudi KLE Technological University Hubli, Karnataka, India 2021 Article history: Received 13 February 2017 Received in revised form 14 April 2017 Accepted 14 May 2017 Available online 20 May 2017.
- [22] Robin Singh Bhadoria / Manish Kumar Pandey/ RVFR: Random vector forest regression model for integrated & enhanced / Received 3 March 2020; Accepted 18 March 2020; Published 23 April 2020.
- [23] Tran Xuan Truong , Viet-Ha Nhu , Doan Thi Nam Phuong , Le Thanh Nghi , Nguyen Nhu Hung, Pham Viet Hoa ,and Dieu Tien Bui / A New Approach Based on TensorFlow Deep Neural Networks with ADAM Optimizer and GIS for Spatial Prediction of Forest Fire Danger in Tropical Area / Received: 6 June 2023 Revised: 2 July 2023 Accepted: 3 July 2023 Published: 8 July 2023.
- [24] Haoyuan Hong ,Paraskevas Tsangaratos , Ioanna Ilia , Junzhi Liu ,A-Xing Zhu ,Chong Xu / Applying genetic algorithms to set the optimal combination of forest fire related variables and model forest fire susceptibility based on data / Received 23 November 2017 Received in revised form 22 February 2018 Accepted 23 February 2018.
- [25] N. Desbois, A. Vidal. La télédétection dans la prévision des incendies de forêts. Ingénieries eau, agriculture-territoires.
- [26] <http://www.algerie-monde.com/> (consulté le 11/02/2024).
- [27] https://dateandtime.info/fr/citycoordinates.php?google_vignette (consulté le 24/03/2024).
- [28]<https://www.aniref.dz/DocumentsPDF/monographies/MONOGRAPHIE%20WILAYA%20BEJAI> A.pdf (consulté le 4/02/2024).
- [29] Feux de forêt à Béjaïa: Plus de 1 500 ha de végétations brûlés | Le jour d'Algérie (lejourdalgerie.com).
- [30] Qu'est-ce qu'un SIG ? SIG : SIG : Tout savoir sur les Systèmes d'Information Géographique | Esri France (consulté le 07/06/2023).
- [31] Le rééchantillonnage : Une méthode <https://datascientest.com/reechantillonnage-tout-savoirage> (consulté le 3/04/2024).
- [32] Support Vector Machine Explained <https://towardsdatascience.com/support-vector-machine-explained-8bfef2f17e71> (consulté le 8/04/2024).
- [33] How the CART Algorithmè (Classification and Regression Trees) Works - Dataaspirant} (consulté le 15/3/2024).
- [34] La régression logistique, qu'est-ce que c'est ? (Datascientest.com) (consulté le 10/4/2024).

- [35] Un guide complet de la régression logistique (ichi.pro) (consulté le 22/3/2024).
- [36] Réseau de neurones : tout ce qu'il faut savoir <https://experiences.microsoft.fr/articles/intelligence-artificielle/reseau-de-neurones-bases/> (consulter le 12/4/2024).
- [37] Univ-batan2 Dr. Merzougui coucrs machine learning.
- [38] Ensemble learning : définition, fonctionnement et algorithmes url : journal.dunet.fr
- [39] Ensemble methods: bagging, boosting and stacking | by Joseph Rocca | Towards Data Science.
- [40] [Théorie] Apprentissages d'ensemble : bagging, boosting et stacking | by Pierre-Henry Juillard | Medium consulter (3/04/2023).
- [41] Mr BELHADJ AISSA MOSTEFA USTHB Faculté d'Electronique, CONCEPTION D'UN SYSTEME D'INFORMATION GEOGRAPHIQUE ORIENTE OBJET MISE EN ŒUVRE D'UNE APPLICATION AUX RISQUES DE FEUX DE FORET Soutenue publiquement le 16 Mai 2004.
- [42] Alexandrian (1982) en France au CEMAGREF.
- [43] Estimation par télédétection du biovolume végétal pour le calcul de l'indice de combustibilité comparaison entre les différents indices de végétation, cas de la forêt de Chettabah Constantine umc.edu.dz.
- [44] DAGORNE et DUCHÉ, (1993). Protection des forêts contre les incendies & Système d'information Géographique : Application à la commune d'Auribeau sur Siagne (Alpes Maritimes), Article'.
- [45] <https://datascience.eu/wp-content/uploads/2020/04/image-1319.png> (consulté le 13/4/2024).
- [46] <https://qgis.org/fr/site/about/index.html> (consulté le 13/4/2024).
- [47] habibi yahyaoui -tp presentation environment envi - univ batna2.
- [48] Google Colab : la force du cloud pour l'apprentissage automatique (datascientest.com) url : Google Colab.
- [49] TensorFlow, url : TensorFlow (consulté 1/05/2023).
- [50] scikit learn <https://scikit-learn.org/> (consulté le 14/5/2024)
- [51] Pandas : pandas - Python Data Analysis Library (pydata.org) (consulté le 14/5/2024)
- [52] Keras: Keras: Deep Learning for humans (consulté le 14/5/2024)
- [53] Matplotlib url : Matplotlib — Visualization with Python .
- [54] seaborn: seaborn: statistical data visualization — seaborn 0.13.2 documentation (pydata.org) (consulté le 15/05/2024).
- [55] numpy <https://numpy.org/> (consulté le 15/4/2024).
- [56] GeoPandas url : Introduction to GeoPandas — GeoPandas 0.14.4+0.g60c9773.dirty documentation (consulté le 15/4/2024).
- [57] html, css, js url : W3Schools Online Web Tutorials (consulté le 15/5/2024).

- [58] leaflet, url : [Leaflet - a JavaScript library for interactive maps \(leafletjs.com\)](https://leafletjs.com) (consulté le 15/5/2024).
- [59] django, url : [The web framework for perfectionists with deadlines | Django \(djangoproject.com\)](https://djangoproject.com) (consulté le 15/5/2024).
- [60] Multilayer Perceptrons in Machine Learning: A Comprehensive Guide, url : [Multilayer Perceptrons in Machine Learning: A Comprehensive Guide | DataCamp](https://datacamp.com) (consulté le 15/5/2024).
- [61] Accueil | Organisation des Nations Unies pour l'alimentation et l'agriculture (fao.org) (consulté le 8/5.2024).
- [62] python, url : [Welcome to Python.org](https://python.org) (consulté le 19/5/2024).
- [63] Les Dernières Données Disponibles Confirment que les Feux de Forêts Se Multiplient | World Resources Institute (wri.org) (consulté le 2 /05/2024).
- [64] Evaluation et cartographie des feux de forêts généralisés d'août 2021 à Bejaia et Tizi Ouzou : Approche géomatique (researchgate.net) (consulté le 2 /05/2024).
- [65] Qu'est-ce qu'un SIG ? SIG : Tout savoir sur les Systèmes d'Information Géographique | Esri France (consulter le 07/06/2023).
- [66] Que sont les données raster ? ArcGIS Desktop | Desktop GIS Software Suite (esri.com) (consulter le 07/06/2023).
- [67] Boîte à outils SIG Ressources pratiques en IM pour les acteurs de la solidarité - (cartong.org) (consulté le 07/06/2023).
- [68] La FAO main dans la main (consulté le 13/02/2024).
- [69] USGS.gov | Science for a changing world (consulté le 2/03/2024).
- [70] Historique-Météo.net : les archives météo dans le monde entier gratuitement (historique-meteo.net) (consulté le 9/03/2024).
- [71] NASA | LANCE | FIRMS (consulté le 12/03/2024).
- [72] L'apprentissage supervisé : définition et exemples, url : <https://blent.ai/blog/a/apprentissage-supervise-definition> (consulté le 23/5/2024).
- [73] Bejaia Map Illustrations & Vectors url : <https://www.dreamstime.com/illustration/bejaia-map.html> (consulté le 12/4/2024)

Annexe A Système d'information géographique

A.1 Définition

Un système d'information Géographique est un outil informatique permettant de représenter et d'analyser toutes les choses qui existent sur terre (données géographiques) ainsi que tous les événements qui s'y produisent. Toutes les données géographiques ont un point commun : elles ont une localisation dans l'espace. On peut donc les représenter et les visualiser sur une carte. Pour représenter de façon numérique des données géographiques, il y a deux modes fondamentaux : le mode vecteur et le mode raster [65].




Figure 20 Système d'information géographique

A.2 Données raster

Dans sa forme la plus simple, un raster se compose d'une matrice de cellules (ou pixels) organisées en lignes et en colonnes (grille) dans laquelle chaque cellule contient une valeur représentant des informations la température, par exemple. Les rasters sont des photographies aériennes numériques, des images satellite, des images numériques, voire des cartes numérisées [66].

A.3 Données vecteur

La donnée vectorielle représente quant à elle le monde réel à l'aide d'objets géométriques (points, lignes et polygones). À chacun de ces objets sont associés des coordonnées géographiques permettant de les localiser dans l'espace. À ces coordonnées s'ajoutent une composante attributaire qui permet de décrire la donnée en fournissant des informations complémentaires [67].

Annexe B Source des données

B.1 Division administrative et population

Les données sur la division administrative (la population pour chaque niveau administratif) ont été collectées depuis le site web FAO [68].

B.2 couverture végétale et les indices de végétation

Les données sur les types et la densité de végétation et les indices de végétation (NDVI, VHI, ASI et IP) ont été collectées depuis le site web FAO [68].

B.3 composition de sol

Les différentes couches qui composent le jeu de données « Composition sol » ont été obtenues depuis le site FAO. La couche finale a été obtenue par la superposition des différentes couches [68].

B.4 Topographie

Le modèle numérique de terrain a été obtenu depuis le programme "SRTM" (Shuttle Radar Topography Mission), est une mission de la NASA ayant produit des modèles numériques d'élévation (MNE) de la surface de la Terre. Ces modèles fournissent des données topographiques haute résolution à l'échelle mondiale. En utilisant un SIG, nous avons extrait les pentes [69].

B.5 Données climatique

Les données météorologiques ont été obtenues depuis « Historique Météo ». Permet de retrouver le bulletin météo ainsi que les données (température, précipitations, vent, etc.) jour par jour et mois par mois pour plusieurs milliers de villes en France et dans le monde depuis 2009 [70].

B.6 Historiques d'incendies

Les historiques d'incendies ont été obtenus depuis la NASA [71]. Ce site fournit des informations sur l'historique des incendies avec différents systèmes tels que VIIRS. Grâce à ses capacités d'imagerie thermique et infrarouge, il peut détecter les feux de manière précise, même pendant la nuit ou sous la couverture nuageuse.

C Annexe Indice de risque

C.1 Carte de biovolume




Figure 21 : carte de biovolume

C.2 Carte des notes combustibles




Figure 22 Carte des notes de combustibilité

C.3 Carte de proximité des routes




Figure 23 Carte de proximité routes

C.4 Carte de l'indice de voisinage




Figure 24 Carte de voisinage

C.5 Carte de La position des versants




Figure 25 la carte La position des versants